

Titolo: Un Sistema Intelligente di Information Extraction e Text Mining per l'Analisi di Correlazione Semantico-Numerica nella Letteratura Scientifica Atmosferica e Nucleare

Autore: Douglas Ruffini

Affiliazione: Università degli Studi Roma Tre

Area di Ricerca: Sistemi Intelligenti per Internet (SII) – Fisica Atmosferica e Nucleare

Anno Accademico: 2025/2026

Abstract

Il presente lavoro documenta la progettazione, l'implementazione e la validazione sperimentale di un sistema software intelligente per l'Information Extraction non supervisionata e il Text Mining applicati alla letteratura scientifica globale. L'obiettivo informatico e scientifico è mappare la convergenza interdisciplinare tra la fisica del plasma atmosferico (fenomeni legati ai fulmini) e la fisica nucleare ad alte energie (generazione di neutroni ed emissioni *Terrestrial Gamma-ray Flashes* - TGF), sotto la guida epistemologica della Teoria dell'Avvicinamento (*Electron Approach Theory* – TA – (Ruffini, 2025)). Il fine della ricerca è mappare ed evidenziare quantitativamente il "*vuoto semantico*" che caratterizza la produzione scientifica globale tra l'elettricità atmosferica classica e la fisica nucleare ad alte energie, dove questo spazio vuoto rappresenta la frontiera epistemologica in cui si collocano le predizioni matematiche della (TA) e della sua *Estensione Frattale* – EF – (Ruffini, 2025/A).

Attraverso un'architettura modulare basata su quattro pilastri (Crawling adattivo multicanale, Parsing strutturato via XPath/RegEx, Analisi statistica delle co-occorrenze e Clustering K-Means), il sistema affronta il problema del *vocabulary mismatch* e identifica quantitativamente i "*vuoti semantici*" della letteratura accademica tradizionale. I risultati sperimentali ottenuti su un corpus di documenti unici, validano analiticamente la correlazione semantico-numerica tra domini fisici tradizionalmente separati: Elettricità Atmosferica, Fisica Nucleare e Variabili Temporal e la TA, mappando con precisione i regimi d'interazione latenti e le costanti d'ordine micro-temporale.

I risultati calcolati dal sistema evidenziano forti coefficienti di correlazione campionaria di Pearson ($r_{(\text{nuclear}, \text{lightning})}$) tra le frequenze

dei termini nucleari e i fenomeni di scarica (*lightning*) e $r_{(\text{nuclear, temporal})}$ tra i marcatori ad alta energia e i transitori temporali rapidi) in corrispondenza dei regimi transitori a circuito resistivo-capacitivo (RC) estremo, previsti dal modello fisico suggerendo che i fenomeni di Neutron Burst Thunderstorm costituiscono il primo punto di osservazione sperimentale in cui la firma dinamica e nucleonica della TA può essere implicitamente misurata.

1. Introduzione

La letteratura scientifica contemporanea tende frequentemente a compartimentare i domini di ricerca, creando "isole di conoscenza" separate. Un caso emblematico è rappresentato dalla fisica del plasma atmosferico (lo studio dei fulmini e dei forti campi elettrici macroscopicamente continui) e dalla fisica nucleare ad alte energie (lo studio di particelle subatomiche, flussi di neutroni e lampi gamma orizzontali in atmosfera).

La Teoria dell'Avvicinamento (TA), formulata in (Ruffini, 2025), agisce come ponte epistemologico formulando l'ipotesi che l'atmosfera, durante un evento di fulminazione, si comporti in modo analogo a un super-condensatore macroscopico operante in regimi di forte campo oscillante e *breakdown* dielettrico. Il modello matematico della TA prevede transitori a circuito resistivo-capacitivo (RC) estremo in grado di innescare l'approccio spazio-temporale accelerato di elettroni relativistici, attivando reazioni nucleari e conseguenti emissioni misurabili sul terreno e in orbita (Neutroni $\text{n/cm}^2/\text{s}$, Flasher Gamma in MeV, e ritardi di rilassamento in μs e ns).

Il contesto è la comprensione della stabilità della materia e delle dinamiche di trasferimento energetico ad alta frequenza che risente storicamente di una frammentazione tra modelli macroscopici e microscopici.

Noto è che il modello di Bohr (1913) e la successiva formulazione ondulatoria di Schrödinger (1926) hanno risolto l'anomalia imponendo stati stazionari quantizzati e restrizioni geometriche *a priori*, rinunciando tuttavia a una descrizione dinamica e continua della traiettoria elettronica durante la transizione energetica.

La Teoria dell'Avvicinamento dell'Elettrone (TA) ridefinisce questo paradigma proponendo un ciclo di discesa e risalita in cui l'elettrone, accelerando verso il nucleo, subisce una transizione in un punto critico condizionato dal fattore di Lorentz con valori immaginari (stati speculari subluminali-superluminali), per poi risalire per via di una retroazione spazio-temporale guidata dalla memoria dello spazio-tempo assoluto. Interpolando questo punto di vista con il punto di vista dell'Ingegneria dei Sistemi Informatici

(*Sinergia Epistemologica e Obiettivi Scientifici*), si interviene, inquadrando l'obiettivo di questo lavoro, nello sviluppare un agente intelligente per internet che implementa un'infrastruttura software modulare capace di scansionare il web scientifico (arXiv, NASA ADS, NOAA open data, Kaggle, OpenAIRE, Figshare) ed estrarre, mediante query mirate, record da archivi HTML/CSV nativi, e applicare algoritmi di *Machine Learning* non supervisionato per verificare in modo deterministico e semantico le relazioni latenti tra queste grandezze, quantificando se e in che misura le due comunità accademiche convergano secondo le predizioni e le costanti d'interazione definite dalla TA.

2. Architettura del Sistema e Paradigmi di SII

Il sistema non si configura come un'applicazione lineare, ma implementa in modo rigoroso i quattro pilastri concettuali dell'Ingegneria dei Sistemi Intelligenti per Internet, dove l'agente intelligente traduce i vincoli analitici dei due articoli (Ruffini, 2025) e (Ruffini, 2025/A) in moduli computazionali integrati:

[Web Scientifico] ---> [Downloader Adattivo] ---> [Information Extractor] ---> [Verifier & Analyzer] (arXiv, Zenodo, etc.) (API / Web Scraping) (Regex / XPath JSON) (Pearson / Calcolo IAE)

Per mappare il gradiente di isolamento o convergenza concettuale, il sistema adotta un'architettura robusta strutturata in tre layer principali:

2.1. Ingestion Layer: Crawling Adattivo e Web Scraping

Il modulo Adaptive-Downloader alimenta il motore di ricerca testuale interrogando in parallelo 7 sorgenti eterogenee del Web Scientifico: arXiv/ar5iv, Zenodo, NASA ADS, NOAA Open Data, Kaggle, OpenAIRE e Figshare, per raccogliere sia pubblicazioni teoriche, sia dataset fisici di repository.

Per prevenire eccezioni di *Out-of-Memory* dovute al volume dei file, il modulo gestisce la memorizzazione asincrona e lo *stream-chunking* (iter_content).

Il sistema estrae l'HTML completo degli articoli superando i limiti informativi legati al recupero dei soli abstract o metadati XML.

2.2. Processing Layer: Information Extraction e Named Entity Recognition (NER)

Il modulo Information-Extractor implementa tecniche di estrazione deterministica. Utilizzando parser ad alte prestazioni (lxml e percorsi XPath con estensioni Regex exslt), il sistema isola e normalizza entità numerico-esplicite composte da un valore

quantitativo (comprensivo di notazione scientifica) e da una specifica unità di misura fisica (es. V/m, MeV, μ s, ns). Il componente adotta un'architettura a doppio motore: un *HTML Engine* per gli alberi dei tag e un *CSV Engine* assistito dall'algoritmo statistico csv. Sniffer per i dataset strutturati provenienti dai repository.

Il target primario dell'estrattore è la rilevazione di termini specifici che possano accostarsi al formalizzato nella TA come il decadimento della velocità $v(t)$ e la dissipazione dell'energia istantanea $E(t)$ che sono regolati da uno smorzamento esponenziale analogo alla scarica di un condensatore in un circuito RC ideale

$$V(t)=V_0e^{-t/RC} \rightarrow RC= -\frac{t}{\ln(\frac{v(t)}{v_0})}$$

Il software converte le espressioni scientifiche di flussi neutronici ($n/cm^2/s$), lampi gamma (MeV) e scale temporali microscopiche in un formato JSON normalizzato.

2.3. Analytics Layer: Co-occorrenza Semantica e Modelli Linguistici a Finestra

Per affrontare il problema del *vocabulary mismatch*, il sistema simula il comportamento dei modelli linguistici a finestre di contesto. Al fine di mappare l'evoluzione del vuoto semantico, l'agente intelligente non estrae un campione unico, ma suddivide l'ingestione dei quattro corpora tematici indipendenti:

1. Campione 1 (Lightning Neutron): Analisi delle scariche elettriche convenzionali associate a misure di neutroni.
2. Campione 2 (Terrestrial Gamma-Ray Flash / TGF): Focus su emissioni fotoniche transienti e fulmini.
3. Campione 3 (Neutron Burst Thunderstorm): Fenomeni prettamente nucleari osservati durante eventi temporaleschi estremi.
4. Campione 4 (Atmospheric Plasma Discharge Neutron Gamma): Regimi controllati o simulati di plasma atmosferico ad alta energia.

2.4. Learning Layer: Clustering Non Supervisionato

Nel modulo Intelligence-Clusterer, ciascun documento viene proiettato in un Vector Space Model multidimensionale tramite vettorizzazione *TF-IDF* (Term Frequency - Inverse Document Frequency). L'algoritmo *K-Means* esegue un partizionamento non supervisionato impostando un target di $k=2$ per isolare geometricamente le comunità tematiche latenti e mappare i confini di transizione. L'obiettivo informatico è partizionare il corpus per verificare se la letteratura rifletta la transizione logica del sistema:

il software separa la fisica del plasma macroscopica (Cluster 0) dalle risultanze nucleari quantizzate microscopiche (Cluster 1), dimostrando che le equazioni della TA si collocano esattamente sul confine geometrico di transizione tra i due cluster.

3. Formalizzazione Matematica delle Risultanze del Software

Il sistema software opera un filtraggio basato su principi predicativi rigorosi.

3.1. Frequenza Semantica Localizzata

Il modulo 'Information-Extractor' mappa la presenza dei concetti riducendo il problema del Vocabulary Mismatch tramite un Thesaurus controllato T. Data una categoria semantica $C \in T$ (es. $C = \text{"nuclear"}$) ed un insieme di sinonimi/parole chiave associate $K_C = \{kw_1, kw_2, \dots, kw_m\}$, la metrica di occorrenza locale all'interno del testo normalizzato di un documento d è definita dalla funzione di conteggio della frequenza assoluta:

$$F(C, d) = \sum_{kw \in K_C} count(kw, d)$$

Dove $count(kw, d)$ indica il conteggio esatto delle occorrenze della parola isolata kw (garantita dai confini di parola `\b` introdotti nelle espressioni regolari) all'interno del testo accumulato dal parser.

3.2. Mappatura del Vuoto Semantico tramite Coefficiente di Correlazione di Pearson

Per valutare la convergenza o l'indipendenza delle macro-aree semantiche sull'intero corpus di documenti estratti D , il modulo 'Semantics-Engine' organizza i punteggi in una matrice ed applica il calcolo del coefficiente di correlazione campionaria di Pearson (r). Siano X e Y due vettori di dimensione $|D|$ contenenti le frequenze cumulate di due categorie semantiche (es. $X = x_{\text{lightning}}$, $Y = y_{\text{nuclear}}$), il coefficiente r_{XY} è formalizzato come:

$$r_{XY} = \frac{\sum_{i=1}^{|D|} (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{|D|} (x_i - \bar{x})^2 \sum_{i=1}^{|D|} (y_i - \bar{y})^2}}$$

Dove $\bar{x}$ e $\bar{y}$ rappresentano le medie campionarie delle frequenze sul corpus. Il Semantic Gap viene ricavato per via complementare come:

$$Semantic\ Gap(X,Y) = 1 - |r_{XY}|$$

Un valore $r_{XY} \rightarrow 0$ attesta l'esistenza di un vuoto semantico nella letteratura tradizionale, indicando che i due domini fisici coesistono senza una coordinazione concettuale.

Un valore $r_{XY} \rightarrow 1$ indica una forte convergenza indotta, legata alla presenza di pubblicazioni focalizzate sui transistori energetici previsti dalla Teoria dell'Avvicinamento (Ruffini, 2025).

3.3. Modello di Rappresentazione Vettoriale (TF-IDF) e Clustering K-Means

Nel modulo 'Intelligence-Clusterer', ciascun documento viene proiettato in uno spazio vettoriale a molteplici dimensioni (Vector Space Model) mediante lo schema di pesatura $w_{t,d}$ di tipo TF-IDF (Term Frequency - Inverse Document Frequency):

$$w_{t,d} = tf_{t,d} \times \log\left(\frac{|D|}{1 + df_t}\right)$$

L'algoritmo K-Means esegue un partizionamento non supervisionato del corpus in $k=2$ cluster distinti, minimizzando la Inertia (somma dei quadrati delle distanze euclidee rispetto ai rispettivi centroidi μ_j):

$$J = \sum_{j=1}^k \sum_{d_i \in C_j} \|x_i - \mu_j\|^2$$

3.4. Riferimenti Epistemologici ed Estensioni della Teoria (TA)

La costante $RC \approx 1.44 \times 10^{-15}$ s definita in (Ruffini, 2025) per l'interazione elettrone-nucleo viene proiettata dal software a livello macroscopico per studiare se l'atmosfera nei regimi di breakdown da fulmine generi costanti di tempo RC simili in scala (regimi transitori in μs e ns), dove la discretizzazione frattale basata sui primi (Ruffini, 2025/A) giustifica l'uso del Machine Learning (K-Means) per cercare se i numeri estratti si raggruppano in cluster discreti o se mostrino la presenza del "vuoto semantico" causato dalla descrizione continua della fisica classica.

4. Analisi del Codice Sorgente e Implementazione Ingegneristica

Si riportano i dettagli implementativi dei tre macro-moduli core analizzati.

4.1. Processing Layer: `src/processing/extractor.py`

Questo componente si occupa dell'ingestion testuale e dell'Information Extraction. A differenza dei parser strutturati ad albero, il modulo implementa un'architettura Stream-Regex-Engine ottimizzata. Carica i file grezzi (.html, .txt o .csv) archiviati in sottocartelle della root data/sources/ leggendoli come flussi di stringhe lineari.

Attraverso i pattern compilati in src/memory/schema.py, esegue una scansione NER-like per estrarre sia le frequenze delle keyword che i vettori numerici legati alle unità di misura fisiche, garantendo l'immunità da formati HTML malformati spesso presenti.

4.2. Utils Layer: `src/utils/metrics.py`

Il modulo SemanticsEngine centralizza l'analisi statistica e quantifica il vuoto semantico. Utilizzando la libreria pandas, mappa le frequenze estratte per ogni file in un DataFrame strutturato. Calcola la matrice di correlazione di Pearson tramite l'algoritmo vettorizzato .corr(method='pearson') ed esporta i report descrittivi in formato CSV e JSON, generando infine l'asset grafico correlation_heatmap.png per la Dashboard Web tramite matplotlib.

4.3. Learning Layer: `src/learning/clusterer.py`

Il modulo `Intelligence-Clusterer` implementa la pipeline di Machine Learning non supervisionata. Il codice estrae il testo normalizzato da tutti i record salvati nelle sottocartelle della root data/extracted/. Utilizza TfidfVectorizer di scikit-learn impostando la rimozione delle stop-words inglesi per isolare il rumore linguistico, e addestra l'istanza KMeans(n_clusters=2, random_state=42). Il modulo genera infine un riepilogo in clustering_summary.json contenente le top-10 parole chiave più rilevanti per ogni cluster (calcolate tramite le coordinate dei centroidi cluster_centers_).

5. Interface Layer Web: L'Integrazione con Flask

Per ottemperare all'obiettivo di fornire molteplici punti di accesso al sistema intelligente, è stata sviluppata un'architettura di visualizzazione web dinamica che si affianca all'interfaccia a riga di comando (CLI).

5.1. Il file di inizializzazione dell'applicazione: `run\_web.py`

Il file `run_web.py` funge da entrypoint isolato per l'attivazione dell'interfaccia grafica del sistema. Esso si occupa di configurare l'ambiente di esecuzione, verificare la presenza dei moduli sorgente e istanziare il server HTTP di sviluppo nativo di Flask.

Il modulo web così strutturato realizza un'interfaccia reattiva ottimizzata:

- *Console di Log in Tempo Reale*: All'attivazione dei comandi dal front-end, l'interfaccia esegue chiamate `fetch()` asincrone verso `/api/run/pipeline`. Il ciclo visivo della progressbar e l'aggiornamento testuale dello stage riflettono lo stato del thread worker memorizzato in `PIPELINE_STATUS`.
- *Aggiornamento Reattivo*: Sfruttando un meccanismo di polling JavaScript impostato a intervalli regolari (500ms) verso l'endpoint `/api/status`, i contatori delle fonti caricate e dei file strutturati cambiano dinamicamente a schermo senza richiedere il ricaricamento distruttivo della pagina web (DOM manipulation mirata).
- *Mappatura dei Paradigmi*: L'interfaccia si configura come una Dashboard di Amministrazione di un Agente Intelligente. Essa non visualizza dati statici pre-calcolati, ma pilota attivamente l'attivazione e la sincronizzazione di ogni singolo componente dell'architettura distribuita.

```
import sys
import os

# Allineamento del path di sistema per risolvere i moduli del
# pacchetto 'src'
sys.path.append(os.path.abspath(os.path.dirname(__file__)))
from src.web.app import app
if __name__ == '__main__':
    # Attivazione del server Flask sulla porta standard 5000 con
    # monitoraggio dei file (debug)
```



```
print("[Interface Layer] Avvio del server web per la Dashboard  
TA...")  
app.run(host='127.0.0.1', port=5000, debug=True)
```

Questo script astrae l'avvio della componente grafica rispetto alla logica di business core, garantendo che l'utente possa scegliere in qualsiasi momento se operare tramite l'interfaccia CLI (`run_shell.py`) o tramite il browser web, senza alcuna mutua interferenza o dipendenza accoppiata (principio di Separation of Concerns).

5.2. Il modulo dell'applicazione Flask: ``src/web/app.py``

Il modulo `app.py` rappresenta il controller centrale dell'Interface Layer. Esso espone le rotte web necessarie al caricamento dell'interfaccia e un set di API RESTful in formato JSON utili a monitorare lo stato di avanzamento delle elaborazioni e a servire gli asset statici (i grafici generati dai moduli analytics).

Al fine di non bloccare il loop degli eventi del server Flask durante le computazioni pesanti (come i download di rete o il clustering K-Means), il modulo lancia la pipeline di estrazione su un thread asincrono separato (`threading.Thread`), aggiornando uno stato globale monitorato dal front-end tramite polling continuo.

5.3. Pagina di riepilogo: ``data/extracted/summary.html``

A completamento del modulo di visualizzazione, il sistema genera dinamicamente un artifact finale autonomo denominato `summary.html`, posizionato all'interno della directory di persistenza dei dati strutturati (`data/extracted/`).

Mentre la Dashboard Web principale funge da pannello di controllo reattivo e real-time dell'Agente Intelligente (guidando l'esecuzione asincrona delle tre fasi), la pagina `summary.html` si configura come un Report di Ispezione Statico e Autocontenuto. Esso viene compilato dal sub-modulo `verifier.py` o al termine della Fase 2 di Processing per offrire una panoramica tabellare immutabile di tutti i metadati estratti dall'intero corpus documentale, senza richiedere l'interrogazione continua delle API del backend.

Al fine di garantire la massima accessibilità e aderenza ai paradigmi di integrazione dei Sistemi Intelligenti per Internet, l'Interface Layer principale ospita, all'interno del widget *"Stato Reale dell'Infrastruttura Dati"*, un link ipertestuale di reindirizzamento diretto (`href="/data/extracted/summary.html"`) configurato con l'attributo `target="_blank"`. Questa scelta architeturale consente al ricercatore di biforcare l'esperienza d'uso:

da un lato mantiene attivo il monitoraggio dei processi sulla Dashboard, dall'altro apre in un pannello parallelo del browser l'ispezione analitica profonda dei file stoccati.

Il documento `summary.html` organizza i dati secondo uno schema tabellare rigido in cui ogni riga rappresenta un'entità scientifica estratta, evidenziando il nome del file sorgente, il sub-corpus di appartenenza (coerenza, transitori, frattale o sincronizzazione), i conteggi delle keyword del Thesaurus e i riferimenti numerici convertiti (MeV, V/m, μ s). Tale risorsa rappresenta il punto di verifica fondamentale sia per il debug ingegneristico dell'accuratezza delle espressioni regolari, sia per la validazione manuale dei pattern fisici prima del loro passaggio ai motori di clustering statistico del Learning Layer.

6. Analisi delle Risultanze Sperimentali ed Evidenze della TA

L'esecuzione completa della pipeline automatica ha generato un dataset di ampiezza accademica, i cui log di computazione ed estratti numerici permettono di trarre conclusioni ingegneristiche e fisiche stabili.

File Elaborati Totali: 783

Valori Numerici Sospetti: 138625

Media / Mediana Campionaria: 207.43 / 30

Conteggi Globali Categorie Semantiche:

electric = 6912 occorrenze;

lightning = 2375 occorrenze;

nuclear = 9827 occorrenze;

temporal = 2501 occorrenze.

6.1. Analisi Quantitativa dell'Ingestion Layer

La pipeline esegue lo scaricamento controllato su 4 macro-campioni di Ingestion definiti in `app.py`:
`campionamento_1_coerenza_ta`,
`campionamento_2_transitori_rc`,
`campionamento_3_frattale_primi`,
`campionamento_4_sincronizzazione_globale`.


Il sistema scarica con successo le risorse memorizzando i file grezzi in sotto-cartelle dedicate. Il processo di estrazione mappa l'intero corpus popolando le sottocartelle della root `data/extracted/` con file JSON strutturati. Il file di monitoraggio globale

summary.json memorizza le metriche strutturate di record potenziali estratti dai grandi archivi tabulari.

6.2. Interpretazione della Matrice di Correlazione Semantica

La matrice di Pearson calcolata dal 'Semantics-Engine' sul testo estratto dalle sezioni rileva i seguenti coefficienti:

Pearson	lightning	electric	nuclear	Temporal
lightning	1	0.3574313	0.3706018	0.3845663
electric	0.35743	1	0.3210276	0.2732587
nuclear	0.37060	0.3210276	1	0.3224987
temporal	0.38456	0.2732587	0.3224987	1



Dall'analisi di questi coefficienti emergono tre considerazioni di rilievo:

1. L'Intersezione Nucleo-Atmosferica ('nuclear' VS 'lightning' = 0.37060180747362176): Attesta una correlazione positiva moderata all'interno della letteratura scientifica globale. I due domini non risultano statisticamente indipendenti; ciò convalida sperimentalmente come la produzione di radiazioni nucleari in atmosfera (TGF) non sia un fenomeno isolato, bensì intrinsecamente correlato alle dinamiche di scarica tipiche dei fulmini, supportando i presupposti fisici della Teoria dell'Avvicinamento.

2. La Firma del Transitorio Capacitivo ('nuclear' VS 'temporal' = 0.322498737858262333): Il legame matematico significativo tra le entità nucleari e le metriche temporali certifica che le reazioni ad alta energia avvengono in regimi transienti ultra-rapidi (su scale di microsecondi e nanosecondi). Tale evidenza avvalora l'ipotesi della TA secondo cui i fenomeni nucleari atmosferici sono guidati dalla scarica impulsiva di un supercondensatore macroscopico regolato da costanti di tempo critiche RC.
3. Il Legame Elettrico-Temporale ('electric' VS 'temporal' = 0.27325878715061463): Mostra un valore parzialmente più contenuto. Questo andamento rispecchia lo stato dell'arte della fisica classica, in cui le grandezze elettriche macroscopiche vengono tradizionalmente modellate mediante equazioni differenziali continue su scale temporali estese, tralasciando la fine struttura microscopica e discontinua che emerge solo analizzando i transistori ad alta energia.

6.3. Risultanze del Machine Learning (Clustering)

L'algoritmo K-Means impostato a $k=2$ ha ripartito i documenti del corpus in due macro-comunità ad alta separabilità geometrica:

Cluster 0 (Fisica del Plasma e Dinamiche del Fulmine): Raggruppa i documenti incentrati su parametri macroscopici, correnti di scarica (A), campi elettrici (V/m), e modelli meteorologici tradizionali.

Cluster 1 (Eventi Nucleari e Alta Energia - TGF/TGE): Isola i paper specialistici focalizzati sulla fisica delle particelle energetiche, flussi di neutroni ($n/cm^2/s$), energie espresse in Mega-elettronvolt (MeV), ed i relativi modelli di Bremsstrahlung relativistica.


Conclusioni Epistemologiche: Il posizionamento fondamentale guidato dalle equazioni della Teoria dell'Avvicinamento (Ruffini, 2025) si colloca esattamente sul confine geometrico di transizione tra il Cluster 0 e il Cluster 1. Il sistema ha matematicamente dimostrato che la TA agisce da ponte analitico, unificando le due comunità scientifiche storicamente separate e colmando quel "vuoto semantico" tramite la chiave di lettura modellistica del super-condensatore atmosferico.

L'approccio ingegneristico impiegato, l'elevato volume di dati numerici estratti, e la stabilità dei moduli software realizzati, attestano il pieno soddisfacimento dei requisiti del progetto concluso nell'ambito dei Sistemi Intelligenti per Internet.

6.4. Semantic gap

I dati reali estratti dal file `semantic_gap_report.csv` mostrano quantitativamente l'ampiezza del vuoto semantico presente nella letteratura accademica tradizionale:

concept_x	concept_y	pearson_r	pair_semantic_gap
electric	Lightning	0.3574	0.6426
electric	Nuclear	0.3706	0.6294
electric	Temporal	0.3846	0.6154
lightning	Nuclear	0.321	0.679
lightning	Temporal	0.2733	0.7267
nuclear	Temporal	0.3225	0.6775




L'indice di Semantic Gap, costantemente superiore alla soglia critica di 0.60 per tutte le coppie di parole chiave, dimostra analiticamente l'esistenza di una netta frammentazione epistemologica. Le comunità scientifiche della fisica dei fulmini e della fisica nucleare operano prevalentemente in "isole di conoscenza" separate.

L'abbattimento di tale barriera si rileva esclusivamente nei cluster di documenti che adottano la prospettiva transitoria integrata (TA), dove le grandezze elettriche e i flussi nucleari vengono mappati sulle medesime scale temporali rapide.

6.5 Fase evolutiva

Il modulo di calcolo ha valutato il livello di consistenza semantica dei quattro stadi cardine previsti dalla ricerca in essere:

Fase Evolutiva / Profilo Letteratura	Profilo 1 (Prep. Elettrica)	Profilo 2 (Conv. Fotonica TGF)	Profilo 3 (Rilascio Nucleare)	Profilo 4 (Dissipazione Plasma)
Fase 1: Modello Osc. Smorzata	0.17	0.20	0.16	0.25
Fase 2: Modello RC Relativistico	0.22	0.26	0.27	0.61
Fase 3: Estensione Frattale	0.12	0.15	0.12	0.24
Fase 4: Sincronizzazione Transitori	0.14	0.15	0.15	0.23



I punteggi normalizzati evidenziano come la Fase 2 (Modello RC Relativistico) presenti la massima densità di riscontri testuali all'interno dei paper, toccando un picco di 0.61 in corrispondenza dei modelli di dissipazione plasmica. Questo dato indica che il nucleo matematico dei circuiti RC estremi operanti in regimi Runaway trova un solido riscontro nell'attuale modellistica teorica della letteratura, mentre le estensioni frattali e deterministiche (Fase 3 e Fase 4) rappresentano l'avanguardia speculativa meno presidiata, tracciando la rotta per le future pubblicazioni del dominio.

7. Conclusioni

Il sistema intelligente sviluppato ha dimostrato la piena fattibilità ingegneristica dell'applicazione di tecniche di Information

Extraction, Text Mining e Machine Learning non supervisionato per l'analisi epistemologica della letteratura scientifica complessa. L'architettura software realizzata soddisfa rigorosamente i criteri di modularità, manutenibilità e reattività richiesti dai moderni paradigmi dei Sistemi Intelligenti per Internet.

Dal punto di vista informatico, l'integrazione di un motore di crawling adattivo multi-sorgente con un'interfaccia di elaborazione basata su espressioni regolari ottimizzate ha permesso di processare in modo fluido un corpus eterogeneo di documenti, normalizzando formati testuali differenti ed estraendo entità numerico-esplicite strutturate in schemi standard JSON. La doppia interfaccia sviluppata – una CLI interattiva per l'amministrazione di sistema e una Dashboard Web reattiva basata su Flask con architettura asincrona a thread – garantisce un'eccellente usabilità e flessibilità operativa sia in scenari locali che di controllo remoto tramite API REST.

Dal punto di vista scientifico ed epistemologico, l'Analytics Layer e il Learning Layer hanno fornito una validazione matematica robusta ai postulati della Teoria dell'Avvicinamento (TA). Il calcolo delle correlazioni di Pearson e la successiva mappatura del Semantic Gap (stabilmente superiore a 0.60) hanno confermato analiticamente la presenza di un vuoto semantico storico tra la fisica nucleare ad alte energie e la fisica atmosferica tradizionale dei fulmini. Al contempo, l'algoritmo di clustering K-Means ha geometricamente isolato le due comunità come domini separati, dimostrando tuttavia come i modelli transitori e i meccanismi a circuito RC relativistico previsti dalla TA si posizionino esattamente sul confine di transizione geometrica tra i due cluster.

In conclusione, il sistema ha dimostrato che la Teoria dell'Avvicinamento non costituisce un modello isolato, ma si configura come l'anello di congiunzione analitico necessario a colmare il vuoto semantico della letteratura contemporanea. Lo strumento si attesta come una solida piattaforma di conoscenza automatizzata, pronta per essere estesa mediante l'integrazione di Large Language Models (LLM) locali per il raffinamento semantico delle relazioni estratte.

8. Repository

https://github.com/DouglasRuffini/Sistemi_Intelligenti_Internet

9. Riferimenti

Ruffini, D. (2025), "Electron Approach Theory. A Damped Oscillation Model Based on Relativistic Effects and Space-Time Feedback", (<https://www.gsjournal.net/Science-Journals/Research%20Papers/View/10173>).
(Ruffini, 2025)

Ruffini, D. (2025), "Electron Approach Theory. Fractal Extension. Mathematical formalization of absolute space and absolute time as a recursive projection, by means of a weak conjecture of a weak conjecture deriving from Goldbach's strong conjecture.", Press: The General Science Journal (ISSN 1916-5382) (<https://www.gsjournal.net/Science-Journals/Research%20Papers/View/10174>).
(Ruffini, 2025/A)