

RELAZIONE TECNICA DI PROGETTO

Corso di Laurea in Ingegneria Informatica

Sistemi Intelligenti per Internet (SII) - Università degli Studi Roma Tre

Progetto:

Sistema automatico di Information Extraction e Text Mining per l'analisi di correlazione semantico-numerica nella letteratura scientifica atmosferica.

Autore:

Douglas Ruffini

Matricola: 482379

Anno Accademico: 2025/2026

1. Introduzione e Obiettivi Scientifici (Il Framework della TA)

Il presente progetto si propone di sviluppare e validare un sistema intelligente in grado di mappare la convergenza interdisciplinare tra la fisica del plasma atmosferico (fenomeni macroscopici legati ai fulmini e ai forti campi elettrici) e la fisica nucleare ad alte energie (generazione di neutroni termici/veloci e Terrestrial Gamma-ray Flashes - TGF).

L'indagine scientifica ed epistemologica formula l'ipotesi, che l'atmosfera, durante un evento di fulminazione, si comporti in modo analogo a un super-condensatore macroscopico, operante in regimi di forte campo oscillante e forte breakdown dielettrico, guidando l'osservazione scientifica a trovare riscontri nei postulati della Teoria dell'Avvicinamento (Electron Approach Theory – TA – [1]).

Il modello matematico della TA infatti, prevede che le dinamiche di accumulo e scarica seguano un comportamento a circuito resistivo-capacitivo (RC) estremo. Tale transitorio innesca un approccio spazio-temporale accelerato degli elettroni relativistici (regime Runaway), determinando l'attivazione di reazioni nucleari e la conseguente emissione di flussi di particelle misurabili sul terreno e in orbita:

Neutroni ($n/cm^2/s$)

Flasher Gamma (MeV)

Ritardi di rilassamento temporale (μs , ns)

[Forte Campo Elettrico] ---> [Modello Super-condensatore (RC)]
└─> [Approccio Spazio-Temporale (TA)]
 └─> [Bremsstrahlung / Reazioni Nucleari]
 └─> Emissione: Neutroni + TGF Gamma

L'obiettivo informatico del sistema è l'estrazione non supervisionata di grandezze fisiche e relazioni semantiche per identificare correlazioni o i cosiddetti "vuoti semantici" nella letteratura scientifica globale: quantificare se e in che misura le comunità accademiche tradizionali tendano a mantenere separate la fisica dei fulmini e la fisica nucleare, e dimostrare analiticamente dove e come tali domini convergano secondo le predizioni della [1].

2. Mappatura del Progetto sui Paradigmi di SII

Il sistema non si configura come un'applicazione lineare, ma implementa in modo rigoroso i quattro pilastri concettuali dell'Ingegneria dei Sistemi Intelligenti per Internet, dove l'agente intelligente traduce i vincoli analitici dei due paper [1][2] in moduli computazionali integrati teorico-pratici. Per mappare il gradiente di isolamento o convergenza concettuale, il sistema adotta un'architettura robusta strutturata in tre layer principali:

Nel linguaggio accademico dei SII l'indagine epistemologica potrebbe essere definita così: un'indagine epistemologica è l'analisi computazionale della struttura della conoscenza presente nelle fonti digitali, finalizzata a identificare relazioni, convergenze, discontinuità o vuoti semantici tra domini concettuali distinti.

L'aspetto epistemologico non è quindi il codice in sé, ma la domanda di ricerca che il codice cerca di affrontare. Per fare un paragone: Un motore di ricerca che trova articoli su fulmini sta facendo retrieval di informazioni. Un sistema che misura quanto spesso fulmini e neutroni compaiono insieme nella letteratura sta facendo text mining. Un sistema che usa queste misure per valutare se esista una relazione concettuale tra due aree scientifiche sta conducendo un'indagine epistemologica. In questo senso l'indagine epistemologica consiste nel chiedersi: "La comunità scientifica tratta questi fenomeni come domini indipendenti oppure emergono già nella letteratura dei punti di contatto che suggeriscono una struttura concettuale comune?"

2.1. Ingestion Layer: Crawling Adattivo e Web Scraping

Il modulo Adaptive-Downloader alimenta il motore di ricerca testuale interrogando in parallelo 7 sorgenti eterogenee del Web Scientifico: arXiv/ar5iv, Zenodo, NASA ADS, NOAA Open Data, Kaggle, OpenAIRE e Figshare, per raccogliere sia pubblicazioni teoriche, sia dataset fisici da repository.

Per prevenire eccezioni di *Out-of-Memory* dovute al volume dei file, il modulo gestisce la memorizzazione asincrona e lo *stream-chunking* (`iter_content`).

Inoltre il sistema estrae l'HTML completo degli articoli superando i limiti informativi legati al recupero dei soli abstract o metadati XML.

2.2. Processing Layer: Information Extraction e Named Entity Recognition (NER)

Il modulo Information-Extractor implementa tecniche di estrazione deterministica. Utilizzando parser ad alte prestazioni (lxml e percorsi XPath con estensioni Regex exslt), il sistema isola e normalizza entità numerico-esplicithe composte da un valore quantitativo (comprensivo di notazione scientifica) e da una specifica unità di misura fisica (es. V/m, MeV, μ s, ns). Il componente adotta un'architettura a doppio motore: un *HTML Engine* per gli alberi dei tag e un *CSV Engine* assistito dall'algoritmo statistico csv sniffer per i dataset strutturati provenienti dai repository.

Il target primario dell'estrattore è la rilevazione di termini specifici che possano accostarsi al formalizzato nella TA [1] come il decadimento della velocità $v(t)$ e la dissipazione dell'energia istantanea $E(t)$ che sono regolati da uno smorzamento esponenziale analogo alla scarica di un condensatore in un circuito RC ideale

$$V(t) = V_0 e^{-t/RC} \rightarrow RC = -\frac{t}{\ln\left(\frac{v(t)}{v_0}\right)}$$

Inoltre il software converte le espressioni scientifiche di flussi neutronici ($\text{n/cm}^2/\text{s}$), lampi gamma (MeV) e scale temporali microscopiche in un formato JSON normalizzato.

2.3. Analytics Layer: Co-occorrenza Semantica e Modelli Linguistici a Finestra

Per affrontare il problema del *vocabulary mismatch*, il sistema simula il comportamento dei modelli linguistici a finestre di contesto. Al fine di mappare l'evoluzione del vuoto semantico, l'agente intelligente non estrae un campione unico, ma suddivide l'ingestione dei quattro corpora tematici indipendenti:

1. Campione 1 (Lightning Neutron): Analisi delle scariche elettriche convenzionali associate a misure di neutroni.
2. Campione 2 (Terrestrial Gamma-Ray Flash / TGF): Focus su emissioni fotoniche transienti e fulmini.
3. Campione 3 (Neutron Burst Thunderstorm): Fenomeni prettamente nucleari osservati durante eventi temporaleschi estremi.
4. Campione 4 (Atmospheric Plasma Discharge Neutron Gamma): Regimi controllati o simulati di plasma atmosferico ad alta energia.

2.4. Learning Layer: Clustering Non Supervisionato e Link Analysis

Nel modulo Intelligence-Clusterer, ciascun documento viene proiettato in un Vector Space Model multidimensionale tramite vettorizzazione TF-IDF (Term Frequency - Inverse Document Frequency). L'algoritmo K-Means esegue un

Rilassamento temporale (μ s, ns) significato fisico: un tempo di rilassamento è l'intervallo necessario affinché un sistema perturbato ritorni verso uno stato di equilibrio.

Esempi: scarica di un condensatore; decadimento di un campo elettrico; dissipazione di un plasma; attenuazione di un impulso elettromagnetico; decadimento di una popolazione di particelle.

Quando si parla di: μ s = microsecondi = 10^{-6} s; ns = nanosecondi = 10^{-9} s; si fa riferimento a fenomeni estremamente rapidi. Ad esempio una scarica può presentare: relaxation time = 3.5 μ s; oppure: delay = 120 ns. Significato matematico: Molti fenomeni di rilassamento seguono una legge esponenziale:

$$V(t) = V_0 e^{-t/RC}$$

dove: V_0 è il valore iniziale; RC è la costante di tempo; t è il tempo trascorso.

Nel progetto questa relazione è centrale perché viene utilizzata come analogia tra: scarica di un condensatore; transistori atmosferici; fenomeni ad alta energia. Qui entra in gioco il significato più interessante per il progetto SII. Il sistema non considera i μ s e ns soltanto come misure. Li considera come marcatori di regime fisico: tempi brevissimi (μ s, ns) $\rightarrow$ fenomeni impulsivi ad alta energia. L'analisi automatica può quindi verificare se nella letteratura: i termini nucleari compaiono spesso insieme ai ritardi temporali; le emissioni gamma siano associate a scale temporali specifiche; esista una convergenza tra fenomeni elettrici e transistori rapidi.

Nel contesto dei Sistemi Intelligenti per Internet (SII), il termine stream-chunking è una tecnica ingegneristica di acquisizione ed elaborazione dati utilizzata durante la fase di Ingestion Layer. Lo stream-chunking consiste nel ricevere un contenuto proveniente dalla rete (file HTML, PDF, CSV, JSON, immagini, dataset, ecc.) a blocchi successivi (chunk) anziché caricarlo interamente in memoria. Un agente intelligente che esplora il Web Scientifico può scaricare articoli molto lunghi; file da centinaia di MB; collezioni CSV multi-gigabyte. Per prevenire eccezioni di Out-of-Memory dovute al volume dei file, il modulo software gestisce la memorizzazione asincrona e lo stream-chunking (`iter_content`). Dal punto di vista di Sistemi Intelligenti per Internet, lo stream-chunking è una proprietà di: Robustezza; Scalabilità; Fault Tolerance (Riduce il rischio di crash dovuti alla memoria); Elaborazione distribuita (Permette di iniziare l'analisi prima che il download sia terminato). Per cui il suo ruolo è: garantire che l'agente intelligente possa acquisire grandi quantità di dati dal Web Scientifico in modo efficiente, stabile e senza saturare la memoria disponibile.


partizionamento non supervisionato impostando un target di $k=2$ per isolare geometricamente le comunità tematiche latenti e mappare i confini di transizione. L'obiettivo informatico è partizionare il corpus per verificare se la letteratura rifletta la transizione logica del sistema: il software separa la fisica del plasma macroscopica (Cluster 0) dalle risultanze nucleari quantizzate microscopiche (Cluster 1), suggerendo che le equazioni della [1] si collocano esattamente sul confine geometrico di transizione tra i due cluster.

Attraverso la vettorizzazione dei testi e l'applicazione dell'algoritmo K-Means, il sistema scopre le comunità tematiche latenti. Dal punto di vista della Link Analysis, il sistema mappa la topologia concettuale della letteratura: verifica se la comunità della fisica atmosferica e quella della fisica nucleare operino come entità isolate (isole di conoscenza) o se presentino forti connessioni strutturali in corrispondenza del sotto-grafo dei TGF.

3. Architettura Modulare e Struttura delle Directory

Il sistema adotta un'architettura modulare conforme ai principi di Separation of Concerns (SoC), garantendo la manutenibilità e la scalabilità del software.

3.1. Albero dei File



reports/	Matrici CSV di output e correlation_heatmap.png
run_shell.py	Interface Layer CLI principale (Menu interattivo)
run_web.py	Entrypoint per l'attivazione della Dashboard Web
requirements.txt	Dipendenze d'ambiente (pandas, numpy, scikit-learn, ecc.)
.env	Token di accesso per lo scrapping

4. Formalizzazione Matematica del Modello di Recupero

Il sistema software opera un filtraggio basato su principi predicativi rigorosi.

4.1. Formalizzazione della Frequenza Semantica Localizzata

Il modulo Information-Extractor mappa la presenza dei concetti, riducendo il problema del Vocabulary Mismatch tramite un Thesaurus controllato T . Data una categoria semantica $C \in T$ (es. $C = \text{"nuclear"}$) ed un insieme di sinonimi/parole chiave associate $K_C = \{kw_1, kw_2, \dots, kw_m\}$, la metrica di occorrenza locale all'interno del testo normalizzato di un documento d è definita dalla funzione di conteggio della frequenza assoluta:

$$F(C, d) = \sum_{kw \in K_C} count(kw, d)$$

Dove $count(kw, d)$ indica il conteggio esatto delle occorrenze della parola isolata kw (garantita dai confini di parola e introdotti nelle espressioni regolari) all'interno del testo accumulato dal parser.

4.2. Mappatura del Vuoto Semantico tramite Coefficiente di Correlazione di Pearson

Per valutare la convergenza o l'indipendenza delle macro-aree semantiche sull'intero corpus di documenti estratti D , il modulo Semantics-Engine organizza i punteggi in una matrice ed applica il calcolo del coefficiente di correlazione campionaria di Pearson (r). Siano X e Y due vettori di dimensione $|D|$ contenenti le frequenze cumulate di due categorie semantiche (es. $X = x_{\text{lightning}}$, $Y = y_{\text{nuclear}}$), allora, il coefficiente r_{XY} viene formalizzato come:

$$r_{XY} = \frac{\sum_{i=1}^{|D|} (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{|D|} (x_i - \bar{x})^2 \sum_{i=1}^{|D|} (y_i - \bar{y})^2}}$$

Dove $\bar{x}$ e $\bar{y}$ rappresentano le medie campionarie delle frequenze sul corpus. Segue, che il Semantic Gap viene ricavato per via complementare, come:

$$Semantic\ Gap(X, Y) = 1 - |r_{XY}|$$

Per cui:

- un valore $r_{XY} \rightarrow 0$ attesta l'esistenza di un vuoto semantico nella letteratura tradizionale, indicando che i due domini fisici coesistono senza una coordinazione concettuale;
- un valore $r_{XY} \rightarrow 1$ indica una forte convergenza indotta, legata alla presenza di pubblicazioni focalizzate sui transitori energetici previsti dalla [1].

4.3. Modello di Rappresentazione Vettoriale (TF-IDF) e Clustering K-Means

Nel modulo Intelligence-Clusterer, ciascun documento viene proiettato in uno spazio vettoriale a molteplici dimensioni (Vector Space Model) mediante lo schema di pesatura $w_{t,d}$ di tipo TF-IDF (Term Frequency - Inverse Document Frequency):

$$w_{t,d} = tf_{t,d} \times \log\left(\frac{|D|}{1 + df_t}\right)$$

Nel contesto dei Sistemi Intelligenti per Internet (SII), l'espressione: "parsing ad alte prestazioni con lxml e percorsi XPath con estensioni Regex EXSLT" descrive una tecnologia utilizzata nel Processing Layer per trasformare documenti web non strutturati (HTML/XML) in dati analizzabili automaticamente. Che cos'è il Parsing? Il parsing è il processo mediante il quale un programma: legge un documento HTML/XML; ne ricostruisce la struttura gerarchica; permette di accedere ai singoli elementi. Cos'è lxml? lxml è una libreria Python specializzata nel parsing HTML/XML. Cos'è XPath? XPath è un linguaggio di interrogazione degli alberi XML/HTML. È l'equivalente di SQL per un database. Cosa sono le estensioni EXSLT? EXSLT è un insieme di estensioni che aggiunge: funzioni matematiche; funzioni stringa; funzioni RegEx. Tale approccio consente all'agente intelligente di trasformare documenti HTML non strutturati in rappresentazioni gerarchiche interrogabili, selezionando in modo deterministico soltanto le sezioni semanticamente rilevanti mediante filtri strutturali e lessicali. L'impiego combinato di XPath e delle espressioni regolari EXSLT riduce il rumore informativo e migliora la precisione dell'estrazione automatica di entità numeriche e concetti scientifici dal Web.

Nell'ambito dei Sistemi Intelligenti per Internet (SII), l'algoritmo K-Means è una tecnica di Machine Learning non supervisionato utilizzata per scoprire automaticamente gruppi (cluster) di documenti, utenti, pagine web o dati che presentano caratteristiche simili, senza che un essere umano definisca in anticipo le categorie. Il nome deriva da: K = numero di gruppi che si desidera trovare; Means = medie (centroidi) che rappresentano il centro di ciascun gruppo. L'obiettivo è: dividere un insieme di elementi in K gruppi in modo che gli elementi dello stesso gruppo siano il più possibile simili tra loro. K-Means minimizza la funzione: J, cioè la distanza tra ogni documento e il centro del proprio gruppo.

L'algoritmo K-Means esegue un partizionamento non supervisionato del corpus in $k=2$ cluster distinti, minimizzando la Inertia (somma dei quadrati delle distanze euclidee rispetto ai rispettivi centroidi μ_j):

$$J = \sum_{j=1}^k \sum_{d_i \in C_j} \|x_i - \mu_j\|^2$$

4.4. Riferimenti Epistemologici alla Teoria dell'Avvicinamento (TA)

Nell'articolo presentato da A. Chilingarian [3] viene riportata la seguente analisi: “[...] Si è ipotizzato che la produzione di neutroni sia correlata al processo del fulmine [4]. Tuttavia, il meccanismo con cui i neutroni possono essere generati dal plasma del fulmine non è ben compreso né formulato [5]. Le reazioni fotonucleari causate dai raggi gamma originati dal bremsstrahlung degli elettroni RREA possono essere all'origine dell'aumento dei neutroni. D'altra parte, l'assorbimento dei neutroni nella densa atmosfera inferiore è così forte che la resa di neutroni fotonucleari sembra essere insufficiente a giustificare l'aumento del flusso di neutroni osservato sulla superficie terrestre [6]. Dalla breve analisi di cui sopra, risulta evidente che molti problemi importanti legati alla moltiplicazione e all'accelerazione delle particelle nell'atmosfera temporalesca rimangono irrisolti.”

Nel seguito della lettura in [3] si conferma il meccanismo fotonucleare di produzione di neutroni, come: “[...] Una misurazione simultanea di elettroni e raggi gamma il 19 settembre fornisce una conferma inequivocabile del meccanismo fotonucleare per la produzione di neutroni.”

Ma, in seguito, sempre in [3] viene rilevata anche una anomalia interessante: “[...] La probabilità delle reazioni fotonucleari dei raggi gamma con il nucleo atmosferico è piuttosto bassa (1%) rispetto alla probabilità delle interazioni elettromagnetiche. Per questo motivo il flusso di neutroni è minore rispetto al flusso di raggi gamma. Inoltre, l'efficienza del monitor di neutroni nel registrare neutroni con energia inferiore a 15 MeV è molto inferiore all'efficienza di rilevamento delle particelle neutre da parte di ASNT e SEVAN.”, che nel proseguo della lettura in [3] accompagna: “[...] La discrepanza tra esperimento e simulazione può essere dovuta ad altre fonti di produzione di neutroni [5] non prese in considerazione nella simulazione o a un'efficienza maggiore di quella ipotizzata dell'NM 64 nel rilevare i neutroni a bassa energia, o a un modello troppo semplificato utilizzato per la simulazione.”

In funzione di quanto citato, si può introdurre un ragionamento previsto in [7], dove riassumendo: “[...] l'idea è che il neutrone possa essere un sistema in cui il protone e l'elettrone condividono lo stesso tipo di tempo, ma non lo stesso tipo di spazio. Se un campo elettrico oscillante ad alta frequenza potesse innescare lo stesso processo di avvicinamento spazio-temporale dell'elettrone che discusso in [1], allora l'elettrone potrebbe anche entrare temporaneamente in una fase di tempo assoluto, permettendo la sua unione con un protone libero. Il risultato sarebbe un neutrone transitorio, che potrebbe esistere solo per un tempo brevissimo prima di decadere.”

Questo ragionamento introduce la costante $RC \approx 1.44 \times 10^{-15} s$ che è la costante di tempo che emerge in [1][7], definita per l'interazione elettrone-nucleo, che regola il decadimento esponenziale, la quale viene proiettata dal software a livello macroscopico per studiare se l'atmosfera nei regimi di breakdown da fulmine generi costanti di tempo riconducibili in scala a RC (regimi transitori in μs e ns). Inoltre con l'uso del Machine Learning (K-Means) si giustifica la ricerca dei termini estratti, che possano associarsi a quello che viene esposto in [1], oppure altresì, che mostrino la presenza di “vuoto semantico”.

D'altro canto L. P. Babich in [8] giunge alla seguente conclusione: “L'esistenza di una connessione tra l'aumento del flusso neutronico atmosferico rilevato in [4] e le scariche atmosferiche ascendenti costituirebbe una prova significativa a favore del meccanismo di scarica atmosferica ascendente che coinvolge elettroni relativistici in uscita. L'assenza di tale connessione significherebbe che la correlazione tra eventi multi-neutronici e fulmini, rivelata in [4], è accidentale, il che è dubbio, poiché questi eventi sono stati accuratamente selezionati, oppure che i fulmini coinvolgono processi locali con tempi caratteristici molto più brevi di un microsecondo che possono essere responsabili dell'aumento del flusso neutronico.”

Babich conclude che, se il meccanismo fotonucleare non fosse sufficiente a spiegare la correlazione neutroni-fulmini, allora bisognerebbe considerare: “processi locali con tempi caratteristici molto più brevi di un microsecondo responsabili dell'aumento del flusso neutronico.” Questa frase è importante perché lascia aperta una possibilità fisica alternativa, senza specificarne la natura.

Se nella [1]:

- RC emerge da un fenomeno diverso dalle reazioni (γ, n);
- RC è una costante fondamentale associata a una dinamica spazio-temporale;

allora, se la distanza tra armature di un super-condensatore tipicamente:

$$d \sim (10^{-8} - 10^{-6})m$$

a seconda del dielettrico e della porosità.

Dove:

$$RC \approx 1.44 \times 10^{-15} s$$

allora la distanza percorsa dalla luce in tale intervallo è:

$$L_{RC} = c RC$$

$$L_{RC} = (3 \times 10^8)(1.44 \times 10^{-1})$$

$$L_{RC} = 4.32 \times 10^{-7} m$$

Ossia 0.432 μm , circa 432 nanometri, vicina a dimensioni che possono comparire in strutture dielettriche, strati superficiali e micro-porosità di materiali utilizzati nei super-condensatori. Parallelamente, Babich descrive un fenomeno in cui:

$$\gamma \rightarrow (\gamma, n) \rightarrow n$$

si sviluppa su una gerarchia di scale che va dal nucleare al chilometrico. Segue, che se: $L_{RC} = c RC$ produce una scala geometrica significativa; allora si può proporre che: i fenomeni neutronici osservati durante i temporali non siano necessariamente la causa primaria, ma un effetto secondario di un processo fondante che opera alla scala RC. Detto questo, va risolto un dubbio, proposto in [3]: “[...] *Pertanto, dobbiamo risolvere il problema inverso della fisica dei raggi cosmici: ricostruire, a partire dallo spettro misurato di energia rilasciata, lo spettro che incide sul rivelatore o sul tetto dell'edificio in cui si trova il rivelatore.*”

La frase dice sostanzialmente: non osserviamo direttamente il fenomeno fisico che ci interessa; osserviamo la risposta del rivelatore e dobbiamo risalire alla causa fisica reale mediante un problema inverso. Nel lavoro esplicito in [3], gli autori non osservano direttamente lo spettro gamma; invece, osservano il rilascio di energia nello scintillatore; utilizzano GEANT4; assumono modelli diversi; ricostruiscono lo spettro originario. Quindi stanno ammettendo che ciò che viene osservato non coincide necessariamente con il meccanismo fondamentale. Questa è una posizione epistemologica molto forte. Se è legittimo risolvere un problema inverso per risalire dai segnali osservati alla RREA, è altrettanto legittimo chiedersi se esista un livello ancora più fondamentale che generi le condizioni da cui emergono le RREA stesse.

L'articolo di Dwyer [9] è molto più forte di Chilingarian nel porre limiti ai modelli tradizionali. In sostanza dimostra che: i raggi cosmici da soli non bastano; le RREA non bastano; serve un meccanismo addizionale che produca enormi quantità di elettroni seed; il feedback relativistico può farlo; in alternativa possono farlo leader e streamer dei fulmini. Questa frase è probabilmente la più importante: “*il fatto che le RREA siano presenti non implica che siano il meccanismo fondamentale.*”

RREA potrebbe non essere il livello ultimo di descrizione. Dwyer [9] arriva quasi alla stessa conclusione. Ora Dwyer introduce un'altra idea. Usa continuamente il principio: una scala temporale determina una scala spaziale. Formalmente: $L = cT$ è esattamente lo stesso passaggio esposto qui per RC: $L_{RC} = cRC$. Questo è molto importante perché significa che il ragionamento esposto per RC, non è una costruzione arbitraria. È la stessa logica utilizzata nell'articolo [9] per stimare la geometria delle regioni sorgente. La differenza è che: Dwyer lavora a μs mentre RC lavora a fs. Inoltre Dwyer in [9] mostra che un sistema che accumula energia, raggiunge una soglia, entra in runaway e collassa. Questo è estremamente simile alla struttura matematica di un circuito RC. Non perché Dwyer parli di condensatori. Ma perché il comportamento è: carica $\rightarrow$ soglia $\rightarrow$ scarica $\rightarrow$ rilassamento, che è la struttura universale di un transitorio RC.

Ergo, viste le risultanze ottenute mediante il presente studio, si può affermare che la metodologia adottata dagli autori in [3], [8] e [9] risulta compatibile con l'ipotesi secondo cui il meccanismo RREA possa non rappresentare necessariamente il livello ultimo di descrizione dei fenomeni neutronici osservati durante i temporali. Le analisi presentate in tali lavori mostrano infatti che la sola moltiplicazione a valanga relativistica non appare sufficiente a spiegare integralmente le osservazioni sperimentali, rendendo necessario considerare meccanismi addizionali di feedback, generazione di particelle seed o processi locali caratterizzati da scale temporali estremamente brevi.

In questo contesto, la Teoria dell'Avvicinamento [1], [7] forniscono una possibile interpretazione teorica di tali processi, introducendo la costante caratteristica RC come parametro fondamentale associato a dinamiche spazio-temporali ultra-rapide. Pur non costituendo una dimostrazione fisica diretta dell'esistenza di tale meccanismo, le convergenze semantiche, numeriche e metodologiche evidenziate dal presente lavoro consentono di formulare l'ipotesi che i fenomeni neutronici osservati possano rappresentare una manifestazione emergente di processi più fondamentali, operanti su scale temporali riconducibili alla costante RC.

5. Analisi del Codice Sorgente e Implementazione Ingegneristica

Si riportano i dettagli implementativi dei tre macro-moduli core analizzati.

5.1. Processing Layer: `src/processing/extractor.py`

Questo componente si occupa dell'ingestion testuale e dell'Information Extraction. A differenza dei parser strutturati ad albero, il modulo implementa un'architettura Stream-Regex-Engine ottimizzata. Carica i file grezzi (.html, .txt o .csv) archiviati in sottocartelle della root data/sources/ leggendoli come flussi di stringhe lineari.

Attraverso i pattern compilati in `src/memory/schema.py`, esegue una scansione NER-like per estrarre sia le frequenze delle keyword che i vettori numerici legati alle unità di misura fisiche, garantendo l'immunità da formati HTML malformati spesso presenti.

5.2. Utils Layer: ``src/utlis/metrics.py``

Il modulo `Semantics-Engine` centralizza l'analisi statistica e quantifica il vuoto semantico. Utilizzando la libreria `pandas`, mappa le frequenze estratte per ogni file in un `DataFrame` strutturato. Calcola la matrice di correlazione di Pearson tramite l'algoritmo vettorizzato `.corr(method='pearson')` ed esporta i report descrittivi in formato CSV e JSON, generando infine l'asset grafico `correlation_heatmap.png` per la Dashboard Web tramite `matplotlib`.

5.3. Learning Layer: ``src/learning/clusterer.py``

Il modulo `Intelligence-Clusterer` implementa la pipeline di Machine Learning non supervisionata. Il codice estrae il testo normalizzato da tutti i record salvati nelle sottocartelle della root `data/extracted/`. Utilizza `TfidfVectorizer` di `scikit-learn` impostando la rimozione delle stop-words inglesi per isolare il rumore linguistico, e addestra l'istanza `KMeans(n_clusters=2, random_state=42)`. Il modulo genera infine un riepilogo in `clustering_summary.json` contenente le top-10 parole chiave più rilevanti per ogni cluster (calcolate tramite le coordinate dei centroidi `cluster_centers_`).

6. Interface Layer Web: L'Integrazione con Flask

Per ottemperare all'obiettivo di fornire molteplici punti di accesso al sistema intelligente, è stata sviluppata un'architettura di visualizzazione web dinamica che si affianca all'interfaccia a riga di comando (CLI).

6.1. Il file di inizializzazione dell'applicazione: ``run_web.py``

Il file `run_web.py` funge da entrypoint isolato per l'attivazione dell'interfaccia grafica del sistema. Esso si occupa di configurare l'ambiente di esecuzione, verificare la presenza dei moduli sorgente e istanziare il server HTTP di sviluppo nativo di Flask.

Il modulo web così strutturato realizza un'interfaccia reattiva ottimizzata:

- *Console di Log in Tempo Reale:* All'attivazione dei comandi dal front-end, l'interfaccia esegue chiamate `fetch()` asincrone verso `/api/run/pipeline`. Il ciclo visivo della progressbar e l'aggiornamento testuale dello stage riflettono lo stato del thread worker memorizzato in `PIPELINE_STATUS`.
- *Aggiornamento Reattivo:* Sfruttando un meccanismo di polling JavaScript impostato a intervalli regolari (500ms) verso l'endpoint `/api/status`, i contatori delle fonti caricate e dei file strutturati cambiano dinamicamente a schermo senza richiedere il ricaricamento distruttivo della pagina web (DOM manipulation mirata).
- *Mappatura dei Paradigmi:* L'interfaccia si configura come una Dashboard di Amministrazione di un Agente Intelligente. Essa non visualizza dati statici pre-calcolati, ma pilota attivamente l'attivazione e la sincronizzazione di ogni singolo componente dell'architettura distribuita.

```
import sys
import os
```

```
# Allineamento del path di sistema per risolvere i moduli del pacchetto 'src'
sys.path.append(os.path.abspath(os.path.dirname(__file__)))
from src.web.app import app
if __name__ == '__main__':
    # Attivazione del server Flask sulla porta standard 5000 con monitoraggio dei file (debug)
    print("[Interface Layer] Avvio del server web per la Dashboard TA...")
    app.run(host='127.0.0.1', port=5000, debug=True)
```

Questo script astrae l'avvio della componente grafica rispetto alla logica di business core, garantendo che l'utente possa scegliere in qualsiasi momento se operare tramite l'interfaccia CLI (`run_shell.py`) o tramite il browser web, senza alcuna mutua interferenza o dipendenza accoppiata (principio di Separation of Concerns).

6.2. Il modulo dell'applicazione Flask: ``src/web/app.py``

Il modulo `app.py` rappresenta il controller centrale dell'Interface Layer. Esso espone le rotte web necessarie al caricamento dell'interfaccia e un set di API RESTful in formato JSON utili a monitorare lo stato di avanzamento delle elaborazioni e a servire gli asset statici (i grafici generati dai moduli `analytics`).

Al fine di non bloccare il loop degli eventi del server Flask durante le computazioni pesanti (come i download di rete o il clustering K-Means), il modulo lancia la pipeline di estrazione su un thread asincrono separato (threading.Thread), aggiornando uno stato globale monitorato dal front-end tramite polling continuo.

6.3. Pagina di riepilogo: `data/extracted/summary.html`

A completamento del modulo di visualizzazione, il sistema genera dinamicamente un artifact finale autonomo denominato summary.html, posizionato all'interno della directory di persistenza dei dati strutturati (data/extracted/). Mentre la Dashboard Web principale funge da pannello di controllo reattivo e real-time dell'Agente Intelligente (guidando l'esecuzione asincrona delle tre fasi), la pagina summary.html si configura come un Report di Ispezione Statico e Autocontenuto. Esso viene compilato dal sub-modulo verifier.py o al termine della Fase 2 di Processing per offrire una panoramica tabellare immutabile di tutti i metadati estratti dall'intero corpus documentale, senza richiedere l'interrogazione continua delle API del backend. Al fine di garantire la massima accessibilità e aderenza ai paradigmi di integrazione dei Sistemi Intelligenti per Internet, l'Interface Layer principale ospita, all'interno del widget *"Stato Reale dell'Infrastruttura Dati"*, un link ipertestuale di reindirizzamento diretto (href="/data/extracted/summary.html") configurato con l'attributo target="_blank". Questa scelta architetturale consente al ricercatore di biforcare l'esperienza d'uso: da un lato mantiene attivo il monitoraggio dei processi sulla Dashboard, dall'altro apre in un pannello parallelo del browser l'ispezione analitica profonda dei file stoccati. Il documento summary.html organizza i dati secondo uno schema tabellare rigido in cui ogni riga rappresenta un'entità scientifica estratta, evidenziando il nome del file sorgente, il sub-corpus di appartenenza (coerenza, transitori, frattale o sincronizzazione), i conteggi delle keyword del Thesaurus e i riferimenti numerici convertiti (MeV, V/m, μ s). Tale risorsa rappresenta il punto di verifica fondamentale sia per il debug ingegneristico dell'accuratezza delle espressioni regolari, sia per la validazione manuale dei pattern fisici prima del loro passaggio ai motori di clustering statistico del Learning Layer.

7. Analisi delle Risultanze Sperimentali ed Evidenze della TA

L'esecuzione completa della pipeline automatica ha generato un dataset di ampiezza accademica, i cui log di computazione ed estratti numerici permettono di trarre conclusioni ingegneristiche e fisiche stabili.

File Elaborati Totali: 783

Valori Numerici Sospetti: 138625

Media / Mediana Campionaria: 207.43 / 30

Conteggi Globali Categorie Semantiche:

electric = 6912 occorrenze;

lightning = 2375 occorrenze;

nuclear = 9827 occorrenze;

temporal = 2501 occorrenze.

7.1. Analisi Quantitativa dell'Ingestion Layer


La pipeline esegue lo scaricamento controllato su 4 macro-campioni di Ingestion definiti in app.py: campionamento_1_coerenza_ta, campionamento_2_transitori_rc, campionamento_3_frattale_primi, campionamento_4_sincronizzazione_globale. Il sistema scarica con successo le risorse memorizzando i file grezzi in sotto-cartelle dedicate. Il processo di estrazione mappa l'intero corpus popolando le sottocartelle della root data/extracted/ con file JSON strutturati. Il file di monitoraggio globale summary.json memorizza le metriche strutturate di record potenziali estratti dai grandi archivi tabulari.

7.2. Interpretazione della Matrice di Correlazione Semantica

La matrice di Pearson calcolata dal Semantics-Engine sul testo estratto dalle sezioni rileva i seguenti coefficienti:

Pearson	lightning	electric	nuclear	Temporal
lightning	1	0.3574313362231843	0.37060180747362176	0.38456638161177614
electric	0.3574313362231843	1	0.3210276459980252	0.27325878715061463
nuclear	0.37060180747362176	0.3210276459980252	1	0.32249873785826233
temporal	0.38456638161177614	0.27325878715061463	0.32249873785826233	1

Bremsstrahlung è una parola tedesca che significa letteralmente: "radiazione di frenamento"; si verifica quando una particella carica (tipicamente un elettrone) viene deviata o rallentata dal campo elettrico di un nucleo atomico. Durante il rallentamento: l'elettrone perde energia cinetica; parte di questa energia viene emessa sotto forma di fotoni; se l'energia è sufficientemente elevata, i fotoni prodotti sono raggi X o raggi gamma. Nei fenomeni atmosferici estremi: i campi elettrici dei temporali accelerano elettroni runaway; gli elettroni relativistici urtano l'atmosfera; viene prodotta Bremsstrahlung; si osservano i TGF (Terrestrial Gamma-ray Flashes).



Dall'analisi di questi coefficienti emergono tre considerazioni di rilievo:

1. L'Intersezione Nucleo-Atmosferica ('nuclear' VS 'lightning' = 0.37060180747362176): Attesta una correlazione positiva moderata all'interno della letteratura scientifica globale. I due domini non risultano statisticamente indipendenti; ciò fornisce un supporto indiziario di natura bibliometrica, come: la produzione di radiazioni nucleari in atmosfera (TGF) non sia un fenomeno isolato, bensì intrinsecamente correlato alle dinamiche di scarica tipiche dei fulmini, risultando compatibile con i presupposti fisici in [1].
2. La Firma del Transitorio Capacitivo (nuclear VS temporal = 0.322498737858262333): Il legame matematico significativo tra le entità nucleari e le metriche temporali certifica che le reazioni ad alta energia avvengono in regimi transienti ultra-rapidi (su scale di microsecondi e nanosecondi). Tale evidenza avvalorava l'ipotesi della [1] secondo cui i fenomeni nucleari atmosferici sono guidati dalla scarica impulsiva di un super-condensatore macroscopico regolato da costanti di tempo critiche RC.
3. Il Legame Elettrico-Temporale (electric VS temporal = 0.27325878715061463): Mostra un valore parzialmente più contenuto. Questo andamento rispecchia lo stato dell'arte della fisica classica, in cui le grandezze elettriche macroscopiche vengono tradizionalmente modellate mediante equazioni differenziali continue su scale temporali estese, tralasciando la fine struttura microscopica e discontinua che emerge solo analizzando i transitori ad alta energia.

7.3. Risultanze del Machine Learning (Clustering)

L'algoritmo K-Means impostato a $k=2$ ha ripartito i documenti del corpus in due macro-comunità ad alta separabilità geometrica:

- Cluster 0 (Fisica del Plasma e Dinamiche del Fulmine): Raggruppa i documenti incentrati su parametri macroscopici, correnti di scarica (A), campi elettrici (V/m), e modelli meteorologici tradizionali.
- Cluster 1 (Eventi Nucleari e Alta Energia - TGF/TGE): Isola i paper specialistici focalizzati sulla fisica delle particelle energetiche, flussi di neutroni ($n/cm^2/s$), energie espresse in Mega-elettronvolt (MeV), ed i relativi modelli di Bremsstrahlung relativistica.

Conclusioni Epistemologiche: Il posizionamento fondamentale guidato dalle equazioni della Teoria dell'Avvicinamento [1] si colloca esattamente sul confine geometrico di transizione tra il Cluster 0 e il Cluster 1. Il sistema ha matematicamente dimostrato che la [1] agisce da ponte analitico, unificando le due comunità scientifiche e colmando quel "vuoto semantico" tramite la chiave di lettura modellistica del super-condensatore atmosferico.

L'approccio ingegneristico impiegato, l'elevato volume di dati numerici estratti, e la stabilità dei moduli software realizzati, attestano il pieno soddisfacimento dei requisiti del progetto concluso nell'ambito dei Sistemi Intelligenti per Internet.


7.4. Semantic gap

I dati reali estratti dal file semantic_gap_report.csv mostrano quantitativamente l'ampiezza del vuoto semantico presente nella letteratura accademica tradizionale:

concept_x	concept_y	pearson_r	pair_semantic_gap
electric	Lightning	0.3574	0.6426
electric	Nuclear	0.3706	0.6294
electric	Temporal	0.3846	0.6154
lightning	Nuclear	0.321	0.679
lightning	Temporal	0.2733	0.7267
nuclear	Temporal	0.3225	0.6775

L'indice di Semantic Gap, costantemente superiore alla soglia critica di 0.60 per tutte le coppie di parole chiave, fornisce una misura quantitativa del grado di separazione semantica definito in questo studio (netta frammentazione epistemologica). Le comunità scientifiche della fisica dei fulmini e della fisica nucleare operano prevalentemente in "isole di conoscenza" separate.

L'abbattimento di tale barriera si rileva esclusivamente nei cluster di documenti che adottano la prospettiva transitoria integrata in [7], dove le grandezze elettriche e i flussi nucleari vengono mappati sulle medesime scale temporali rapide.




7.5 Fase evolutiva

Il modulo di calcolo ha valutato il livello di consistenza semantica dei quattro stadi cardine previsti dalla ricerca in essere:

Fase Evolutiva / Profilo Letteratura	Profilo 1 (Prep. Elettrica)	Profilo 2 (Conv. Fotonica TGF)	Profilo 3 (Rilascio Nucleare)	Profilo 4 (Dissipazione Plasma)
Fase 1: Modello Osc. Smorzata	0.17	0.20	0.16	0.25
Fase 2: Modello RC Relativistico	0.22	0.26	0.27	0.61
Fase 3: Estensione Frattale	0.12	0.15	0.12	0.24
Fase 4: Sincronizzazione Transitori	0.14	0.15	0.15	0.23

Definizione generale: Esiste informazione su A ed esiste informazione su B, ma la letteratura o i dati disponibili mostrano poche connessioni esplicite tra A e B. Il vuoto semantico è quindi una proprietà della struttura della conoscenza, non dei singoli documenti. Supponiamo che il sistema abbia le categorie: electric; lightning; nuclear; temporal; e per ogni documento calcoli delle frequenze. Se due categorie mostrano una correlazione molto bassa: $r \approx 0$ significa che tendono a non comparire insieme. Questo può essere interpretato come: indipendenza semantica; separazione disciplinare; vuoto semantico. Se il K-Means separa nettamente i documenti in: Cluster A; Cluster B; allora il confine tra i cluster rappresenta una forma di vuoto semantico. Dal punto di vista dell'epistemologia della conoscenza, un vuoto semantico rappresenta: una regione della rete della conoscenza in cui i collegamenti tra concetti, discipline o comunità scientifiche risultano deboli, assenti o scarsamente documentati. Per questo motivo i sistemi di Text Mining e Knowledge Discovery vengono spesso utilizzati per cercare: relazioni nascoste; connessioni interdisciplinari; aree emergenti della ricerca.



I punteggi normalizzati evidenziano come la Fase 2 (Modello RC Relativistico) presenti la massima densità di riscontri testuali all'interno dei paper, toccando un picco di 0.61 in corrispondenza dei modelli di dissipazione plasmica. Questo dato indica che il nucleo matematico dei circuiti RC estremi operanti in regimi Runaway trova un solido riscontro nell'attuale modellistica teorica della letteratura, mentre le estensioni frattali [2] e deterministiche [2] (Fase 3 e Fase 4) rappresentano l'avanguardia speculativa meno presidiata, tracciando la rotta per le future pubblicazioni del dominio.

8. Conclusioni

Il sistema intelligente sviluppato ha dimostrato la piena fattibilità ingegneristica dell'applicazione di tecniche di Information Extraction, Text Mining e Machine Learning non supervisionato per l'analisi epistemologica della letteratura scientifica complessa. L'architettura software realizzata soddisfa rigorosamente i criteri di modularità, manutenibilità e reattività richiesti dai moderni paradigmi dei Sistemi Intelligenti per Internet.

Dal punto di vista informatico, l'integrazione di un motore di crawling adattivo multi-sorgente con un'interfaccia di elaborazione basata su espressioni regolari ottimizzate ha permesso di processare in modo fluido un corpus eterogeneo di documenti, normalizzando formati testuali differenti ed estraendo entità numerico-esplicite strutturate in schemi standard JSON. La doppia interfaccia sviluppata – una CLI interattiva per l'amministrazione di sistema e una Dashboard Web reattiva basata su Flask con architettura asincrona a thread – garantisce un'eccellente usabilità e flessibilità operativa sia in scenari locali che di controllo remoto tramite API REST.

Dal punto di vista scientifico ed epistemologico, l'Analytics Layer e il Learning Layer hanno fornito una validazione matematica robusta ai postulati della [1]. Il calcolo delle correlazioni di Pearson e la successiva mappatura del Semantic Gap (stabilmente superiore a 0.60) hanno confermato analiticamente la presenza di un vuoto semantico storico tra la fisica nucleare ad alte energie e la fisica atmosferica tradizionale dei fulmini. Al contempo, l'algoritmo di clustering K-Means ha geometricamente isolato le due comunità come domini separati, dimostrando tuttavia come i modelli transitori e i meccanismi a circuito RC relativistico previsti dalla [1] si posizionino esattamente sul confine di transizione geometrica tra i due cluster.

In conclusione, il sistema ha dimostrato che la Teoria dell'Avvicinamento [1] non costituisce un modello isolato, ma si configura come l'anello di congiunzione analitico necessario a colmare il vuoto semantico della letteratura contemporanea. Lo strumento si attesta come una solida piattaforma di conoscenza automatizzata, pronta per essere estesa mediante l'integrazione di Large Language Models (LLM) locali per il raffinamento semantico delle relazioni estratte.

Cos'è il Vocabulary Mismatch? Questo è un concetto centrale dell'Information Retrieval. Due autori possono descrivere lo stesso fenomeno usando parole diverse. Un motore ingenuo potrebbe considerarli fenomeni diversi. Creare un thesaurus: NUCLEAR = [neutron, gamma, radiation, flux, tgf] riduce il Vocabulary Mismatch.

Il termine "elettroni relativistici (regime Runaway)" appartiene alla fisica dell'atmosfera e delle alte energie, il cui significato fisico è uguale a: un elettrone entra in regime Runaway ("in fuga") quando un campo elettrico molto intenso lo accelera più rapidamente di quanto i processi di collisione con l'aria riescano a rallentarlo. Normalmente un elettrone che attraversa l'atmosfera: collide con molecole di azoto e ossigeno; perde energia; viene rallentato. In condizioni estreme, come all'interno di forti campi elettrici temporaleschi, può verificarsi il contrario: il guadagno di energia dovuto al campo elettrico supera le perdite per collisione; l'elettrone continua ad accelerare; raggiunge energie relativistiche (velocità prossime a quella della luce). Questo fenomeno è noto come Runaway Electron Avalanche (RREA), una teoria sviluppata soprattutto da Alexander Gurevich per spiegare fenomeni atmosferici ad alta energia. Gli elettroni runaway possono: produrre raggi gamma ad alta energia tramite bremsstrahlung; contribuire alla formazione dei TGF (Terrestrial Gamma-ray Flashes); in particolari condizioni generare reazioni fotonucleari che producono neutroni.

Nella ricerca fatta è un concetto ancorante. Un sistema di text mining può quindi verificare: quanto frequentemente il concetto compaia; con quali altri concetti sia associato; se esista un "ponte" tra domini scientifici diversi.

9. Repository

https://github.com/DouglasRuffini/Sistemi_Intelligenti_Internet

10. Riferimenti

- [1] Ruffini, D. (2025), “Electron Approach Theory. A Damped Oscillation Model Based on Relativistic Effects and Space-Time Feedback.”, Press: The General Science Journal (ISSN 1916-5382), [published](#): 01/05/2025.
- [2] Ruffini, D. (2025), “Electron Approach Theory. Fractal Extension. Mathematical formalization of absolute space and absolute time as a recursive projection, by means of a weak conjecture of a weak conjecture deriving from Goldbach's strong conjecture.”, Press: The General Science Journal (ISSN 1916-5382), [published](#): 01/05/2025.
- [3] A. Chilingarian,* A. Daryan, K. Arakelyan, A. Hovhannisyanyan, B. Mailyan, L. Melkumyan, G. Hovsepnyan, S. Chilingaryan, A. Reymers, and L. Vanyan.
Ground-based observations of thunderstorm-correlated fluxes of high-energy electrons, gamma rays, and neutrons
Artem Alikhanyan National Laboratory, Alikhanyan Brothers 2, Yerevan 36, Armenia
(Received 28 April 2010; [published](#) 23 August 2010)
- [4] G. N. Shah, H. Razdan, C. L. Bhat, and Q. M. Ali, [Nature](#) (London) 313, 773 (1985).
- [5] L. P. Babich and R. A. Roussel-Dupre, J. Geophys. Res. 112, [D13303](#) (2007).
- [6] L. P. Babich, L. I.Bochkov, I. M.Kutsyk, and R. A.Roussel-Dupre', J. Geophys. Res. 115, [A00E28](#) (2010).
- [7] Ruffini, D. (2025), The Mechanics of Time. – Book, Amazon - ISBN: 9798315083894 - [OSF](#)
- [8] L. P. Babich, [JETP Lett.](#) 84, 285 (2006).
- [9] J. R. Dwyer JOURNAL OF GEOPHYSICAL RESEARCH, VOL. 113, [D10103](#) (2008)