

RELAZIONE TECNICA DI PROGETTO

Corso di Laurea in Ingegneria Informatica

Sistemi Intelligenti per Internet (SII) - Università degli Studi Roma Tre

Progetto:

Sistema automatico di Information Extraction e Text Mining per l'analisi di correlazione semantico-numerica nella letteratura scientifica atmosferica.

Autore:

Douglas Ruffini

Matricola: 482379

Anno Accademico: 2025/2026

1. Introduzione e Obiettivi Scientifici (Il Framework della TA)

Il presente progetto si propone di sviluppare e validare un sistema intelligente in grado di mappare la convergenza interdisciplinare tra la fisica del plasma atmosferico (fenomeni macroscopici legati ai fulmini e ai forti campi elettrici) e la fisica nucleare ad alte energie (generazione di neutroni termici/veloci e Terrestrial Gamma-ray Flashes - TGF).

L'indagine scientifica ed epistemologica formula l'ipotesi, che l'atmosfera, durante un evento di fulminazione, si comporti in modo analogo a un super-condensatore macroscopico, operante in regimi di forte campo oscillante e forte breakdown dielettrico, guidando l'osservazione scientifica a trovare riscontri nei postulati della Teoria dell'Avvicinamento (Electron Approach Theory – TA – [1]).

Il modello matematico della TA infatti, prevede che le dinamiche di accumulo e scarica seguano un comportamento a circuito resistivo-capacitivo (RC) estremo. Tale transitorio innesca un approccio spazio-temporale accelerato degli elettroni relativistici (regime Runaway), determinando l'attivazione di reazioni nucleari e la conseguente emissione di flussi di particelle misurabili sul terreno e in orbita:

Neutroni ($n/cm^2/s$)

Flasher Gamma (MeV)

Ritardi di rilassamento temporale (μs , ns)

[Forte Campo Elettrico] ---> [Modello Super-condensatore (RC)]
└─> [Approccio Spazio-Temporale (TA)]
 └─> [Bremsstrahlung / Reazioni Nucleari]
 └─> Emissione: Neutroni + TGF Gamma

L'obiettivo informatico del sistema è l'estrazione non supervisionata di grandezze fisiche e relazioni semantiche per identificare correlazioni o i cosiddetti "vuoti semantici" nella letteratura scientifica globale: quantificare se e in che misura le comunità accademiche tradizionali tendano a mantenere separate la fisica dei fulmini e la fisica nucleare, e dimostrare analiticamente dove e come tali domini convergano secondo le predizioni della TA [1].

2. Mappatura del Progetto sui Paradigmi di SII

L'architettura software del sistema non si configura come un semplice script di elaborazione lineare, ma implementa in modo rigoroso i concetti fondanti dell'Ingegneria dei Sistemi Intelligenti per Internet, strutturandosi su quattro pilastri teorico-pratici.

2.1. Ingestion Layer: Crawling Adattivo e Web Scraping

Il modulo 'Adaptive-Downloader' agisce come componente di alimentazione di un motore di ricerca testuale avanzato. Interroga simultaneamente 7 sorgenti eterogenee del Web Scientifico (arXiv/ar5iv, Zenodo, NASA ADS, NOAA

Nel linguaggio accademico dei SII l'indagine epistemologica potrebbe essere definita così: un'indagine epistemologica è l'analisi computazionale della struttura della conoscenza presente nelle fonti digitali, finalizzata a identificare relazioni, convergenze, discontinuità o vuoti semantici tra domini concettuali distinti.

L'aspetto epistemologico non è quindi il codice in sé, ma la domanda di ricerca che il codice cerca di affrontare. Per fare un paragone: Un motore di ricerca che trova articoli su fulmini sta facendo retrieval di informazioni. Un sistema che misura quanto spesso fulmini e neutroni compaiono insieme nella letteratura sta facendo text mining. Un sistema che usa queste misure per valutare se esista una relazione concettuale tra due aree scientifiche sta conducendo un'indagine epistemologica. In questo senso l'indagine epistemologica consiste nel chiedersi: "La comunità scientifica tratta questi fenomeni come domini indipendenti oppure emergono già nella letteratura dei punti di contatto che suggeriscono una struttura concettuale comune?"

Open Data, Kaggle, OpenAIRE, Figshare), gestendo la memorizzazione asincrona e lo stream-chunking ('iter_content') dei flussi per prevenire eccezioni di Out-of-Memory.

Il sistema estrae l'HTML completo degli articoli, superando i limiti informativi legati al solo recupero dei metadati XML o degli abstract.

2.2. Processing Layer: Information Extraction e Named Entity Recognition (NER)

Il modulo 'Information-Extractor' implementa tecniche di Information Extraction deterministica e semantica. Attraverso espressioni regolari e l'utilizzo di librerie di, il sistema isola e normalizza entità numerico-esplicite composte da un valore quantitativo (comprensivo di notazione scientifica) e da una specifica unità di misura fisica (es. V/m, MeV, μ s). I record estratti vengono poi convertiti in uno schema JSON normalizzato.

2.3. Analytics Layer: Co-occorrenza Semantica e Language Models

Il calcolo delle interazioni semantiche simula il comportamento dei modelli linguistici a finestre di contesto. Il sistema esamina la frequenza di occorrenza di termini afferenti a un thesaurus controllato entro le sezioni dei documenti (didascalie di tabelle, figure e paragrafi rilevanti), mappando le mutue adiacenze. Questa euristica affronta direttamente il problema del vocabulary mismatch.


2.4. Learning Layer: Clustering Non Supervisionato e Link Analysis

Attraverso la vettorizzazione dei testi e l'applicazione dell'algoritmo K-Means, il sistema scopre le comunità tematiche latenti. Dal punto di vista della Link Analysis, il sistema mappa la topologia concettuale della letteratura: verifica se la comunità della fisica atmosferica e quella della fisica nucleare operino come entità isolate (isole di conoscenza) o se presentino forti connessioni strutturali in corrispondenza del sotto-grafo dei TGF.

3. Architettura Modulare e Struttura delle Directory

Il sistema adotta un'architettura modulare conforme ai principi di Separation of Concerns (SoC), garantendo la manutenibilità e la scalabilità del software.

3.1. Albero dei File



Rilassamento temporale (μ s, ns) significato fisico: un tempo di rilassamento è l'intervallo necessario affinché un sistema perturbato ritorni verso uno stato di equilibrio.

Esempi:

scarica di un condensatore;

decadimento di un campo elettrico;

dissipazione di un plasma;

attenuazione di un impulso elettromagnetico;

decadimento di una popolazione di particelle.

Quando si parla di: μ s = microsecondi = 10^{-6} s; ns = nanosecondi = 10^{-9} s; si fa riferimento a fenomeni estremamente rapidi. Ad esempio una scarica può presentare: relaxation time = 3.5 μ s; oppure: delay = 120 ns. Significato matematico: Molti fenomeni di rilassamento seguono una legge esponenziale: $V(t) = V_0 e^{-(t/RC)}$

dove:

V_0 è il valore iniziale;


RC è la costante di tempo;

t è il tempo trascorso.

Nel progetto questa relazione è centrale perché viene utilizzata come analogia tra: scarica di un condensatore; transitori atmosferici; fenomeni ad alta energia. Qui entra in gioco il significato più interessante per il progetto SII. Il sistema non considera i μ s e ns soltanto come misure. Li considera come marcatori di regime fisico: tempi brevissimi (μ s, ns) $\rightarrow$ fenomeni impulsivi ad alta energia. L'analisi automatica può quindi verificare se nella letteratura: i termini nucleari compaiono spesso insieme ai ritardi temporali; le emissioni gamma siano associate a scale temporali specifiche; esista una convergenza tra fenomeni elettrici e transitori rapidi.

stream-chunking

Nel contesto dei Sistemi Intelligenti per Internet (SII), il termine stream-chunking è una tecnica ingegneristica di acquisizione ed elaborazione dati utilizzata durante la fase di Ingestion Layer. Lo stream-chunking consiste nel ricevere un contenuto proveniente dalla rete (file HTML, PDF, CSV, JSON, immagini, dataset, ecc.) a blocchi successivi (chunk) anziché caricarlo interamente in memoria. Un agente intelligente che esplora il Web Scientifico può scaricare articoli molto lunghi; file da centinaia di MB; collezioni CSV multi-gigabyte. Per prevenire eccezioni di Out-of-Memory dovute al volume dei file, il modulo software gestisce la memorizzazione asincrona e lo stream-chunking (iter_content). Dal punto di vista di Sistemi Intelligenti per Internet, lo stream-chunking è una proprietà di: Robustezza; Scalabilità; Fault Tolerance (Riduce il rischio di crash dovuti alla memoria); Elaborazione distribuita (Permette di iniziare l'analisi prima che il download sia terminato). Per cui il suo ruolo è: garantire che l'agente intelligente possa acquisire grandi quantità di dati dal Web Scientifico in modo efficiente, stabile e senza saturare la memoria disponibile.



4. Formalizzazione Matematica del Modello di Recupero

Il cuore analitico del sistema si fonda sulla formalizzazione statistico-vettoriale delle informazioni estratte.

4.1. Formalizzazione della Frequenza Semantica Localizzata

Il modulo 'Information-Extractor' mappa la presenza dei concetti riducendo il problema del Vocabulary Mismatch tramite un Thesaurus controllato T . Data una categoria semantica $C \in T$ (es. $C = \text{"nuclear"}$) ed un insieme di sinonimi/parole chiave associate $K_C = \{kw_1, kw_2, \dots, kw_m\}$, la metrica di occorrenza locale all'interno del testo normalizzato di un documento d è definita dalla funzione di conteggio della frequenza assoluta:

$$F(C, d) = \sum_{kw \in K_C} count(kw, d)$$

Dove $count(kw, d)$ indica il conteggio esatto delle occorrenze della parola isolata kw (garantita dai confini di parola $\backslash b$ introdotti nelle espressioni regolari) all'interno del testo accumulato dal parser.

4.2. Mappatura del Vuoto Semantico tramite Coefficiente di Correlazione di Pearson

Per valutare la convergenza o l'indipendenza delle macro-aree semantiche sull'intero corpus di documenti estratti D, il modulo 'Semantics-Engine' organizza i punteggi in una matrice ed applica il calcolo del coefficiente di correlazione campionaria di Pearson (r). Siano X e Y due vettori di dimensione |D| contenenti le frequenze cumulate di due categorie semantiche (es. $X = x_{\text{lightning}}$, $Y = y_{\text{nuclear}}$), il coefficiente r_{XY} è formalizzato come:

$$r_{XY} = \frac{\sum_{i=1}^{|D|} (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{|D|} (x_i - \bar{x})^2 \sum_{i=1}^{|D|} (y_i - \bar{y})^2}}$$

Dove $\bar{x}$ e $\bar{y}$ rappresentano le medie campionarie delle frequenze sul corpus. Il Semantic Gap viene ricavato per via complementare come:

$$\text{Semantic Gap}(X, Y) = 1 - |r_{XY}|$$

Un valore $r_{XY} \rightarrow 0$ attesta l'esistenza di un vuoto semantico nella letteratura tradizionale, indicando che i due domini fisici coesistono senza una coordinazione concettuale.

Un valore $r_{XY} \rightarrow 1$ indica una forte convergenza indotta, legata alla presenza di pubblicazioni focalizzate sui transitori energetici previsti dalla Teoria dell'Avvicinamento [1].

4.3. Modello di Rappresentazione Vettoriale (TF-IDF) e Clustering K-Means

Nel modulo 'Intelligence-Clusterer', ciascun documento viene proiettato in uno spazio vettoriale a molteplici dimensioni (Vector Space Model) mediante lo schema di pesatura $w_{t,d}$ di tipo TF-IDF (Term Frequency - Inverse Document Frequency):

$$w_{t,d} = tf_{t,d} \times \log\left(\frac{|D|}{1 + df_t}\right)$$

L'algoritmo K-Means esegue un partizionamento non supervisionato del corpus in $k=2$ cluster distinti, minimizzando la Inertia (somma dei quadrati delle distanze euclidee rispetto ai rispettivi centroidi μ_j):

$$J = \sum_{j=1}^k \sum_{d_i \in C_j} \|x_i - \mu_j\|^2$$

4.4. Riferimenti Epistemologici ed Estensioni della Teoria (TA)

Nell'articolo presentato da A. Chilingarian [3] viene riportata la seguente analisi: "[...] Si è ipotizzato che la produzione di neutroni sia correlata al processo del fulmine [4]. Tuttavia, il meccanismo con cui i neutroni possono essere generati dal plasma del fulmine non è ben compreso né formulato [5]. Le reazioni fotonucleari causate dai raggi gamma originati dal bremsstrahlung degli elettroni RREA possono essere all'origine dell'aumento dei neutroni. D'altra parte, l'assorbimento dei neutroni nella densa atmosfera inferiore è così forte che la resa di neutroni fotonucleari sembra essere insufficiente a giustificare l'aumento del flusso di neutroni osservato sulla superficie terrestre [6]. Dalla breve analisi di cui sopra, risulta evidente che molti problemi importanti legati alla moltiplicazione e all'accelerazione delle particelle nell'atmosfera temporalesca rimangono irrisolti."

Nel contesto dei Sistemi Intelligenti per Internet (SII), l'espressione: "parsing ad alte prestazioni con lxml e percorsi XPath con estensioni Regex EXSLT" descrive una tecnologia utilizzata nel Processing Layer per trasformare documenti web non strutturati (HTML/XML) in dati analizzabili automaticamente. Che cos'è il Parsing? Il parsing è il processo mediante il quale un programma: legge un documento HTML/XML; ne ricostruisce la struttura gerarchica; permette di accedere ai singoli elementi. Cos'è lxml? lxml è una libreria Python specializzata nel parsing HTML/XML. Cos'è XPath? XPath è un linguaggio di interrogazione degli alberi XML/HTML. È l'equivalente di SQL per un database. Cosa sono le estensioni EXSLT? EXSLT è un insieme di estensioni che aggiunge: funzioni matematiche; funzioni stringa; funzioni RegEx. Tale approccio consente all'agente intelligente di trasformare documenti HTML non strutturati in rappresentazioni gerarchiche interrogabili, selezionando in modo deterministico soltanto le sezioni semanticamente rilevanti mediante filtri strutturali e lessicali. L'impiego combinato di XPath e delle espressioni regolari EXSLT riduce il rumore informativo e migliora la precisione dell'estrazione automatica di entità numeriche e concetti scientifici dal Web.

Nell'ambito dei Sistemi Intelligenti per Internet (SII), l'algoritmo K-Means è una tecnica di Machine Learning non supervisionato utilizzata per scoprire automaticamente gruppi (cluster) di documenti, utenti, pagine web o dati che presentano caratteristiche simili, senza che un essere umano definisca in anticipo le categorie. Il nome deriva da: K = numero di gruppi che si desidera trovare; Means = medie (centroidi) che rappresentano il centro di ciascun gruppo. L'obiettivo è: dividere un insieme di elementi in K gruppi in modo che gli elementi dello stesso gruppo siano il più possibile simili tra loro. K-Means minimizza la funzione: J, cioè la distanza tra ogni documento e il centro del proprio gruppo.

Nel seguito della lettura si conferma il meccanismo fotonucleare di produzione di neutroni: “[...] *Una misurazione simultanea di elettroni e raggi gamma il 19 settembre fornisce una conferma inequivocabile del meccanismo fotonucleare per la produzione di neutroni.*”

Ma, in seguito, viene rilevata una anomalia interessante: “[...] *La probabilità delle reazioni fotonucleari dei raggi gamma con il nucleo atmosferico è piuttosto bassa (1%) rispetto alla probabilità delle interazioni elettromagnetiche. Per questo motivo il flusso di neutroni è minore rispetto al flusso di raggi gamma. Inoltre, l'efficienza del monitor di neutroni nel registrare neutroni con energia inferiore a 15 MeV è molto inferiore all'efficienza di rilevamento delle particelle neutre da parte di ASNT e SEVAN.*”, che accompagna: “[...] *La discrepanza tra esperimento e simulazione può essere dovuta ad altre fonti di produzione di neutroni [5] non prese in considerazione nella simulazione o a un'efficienza maggiore di quella ipotizzata dell'NM 64 nel rilevare i neutroni a bassa energia, o a un modello troppo semplificato utilizzato per la simulazione.*”

In funzione di quanto citato, si può introdurre un ragionamento previsto in [7], dove riassumendo: “[...] *l'idea che il neutrone possa essere un sistema in cui il protone e l'elettrone condividono lo stesso tempo, ma non lo stesso spazio, è compatibile con la teoria dell'avvicinamento dell'elettrone descritta nell'articolo [1]. Se un campo elettrico oscillante ad alta frequenza potesse innescare lo stesso processo di avvicinamento spazio-temporale dell'elettrone che ho discusso, allora l'elettrone potrebbe anche entrare temporaneamente in una fase di tempo assoluto, permettendo la sua unione con un protone libero. Il risultato sarebbe un neutrone transitorio, che potrebbe esistere solo per un tempo brevissimo prima di decadere, dando prova della validità di tutto l'assunto.*”

Questo ragionamento introduce la costante $RC \approx 1.44 \times 10^{-15}$ s che è la costante di tempo che emerge in [1], definita per l'interazione elettrone-nucleo, che regola il decadimento esponenziale, la quale viene proiettata dal software a livello macroscopico per studiare se l'atmosfera nei regimi di breakdown da fulmine generi costanti di tempo riconducibili in scala a RC (regimi transitori in μ s e ns). inoltre con l'uso del Machine Learning (K-Means) si giustifica la ricerca dei termini estratti, che possano associarsi a quello che viene esposto in [1], oppure altresì, che mostrino la presenza di "vuoto semantico".

5. Analisi del Codice Sorgente e Implementazione Ingegneristica

Si riportano i dettagli implementativi dei tre macro-moduli core analizzati.

5.1. Processing Layer: `src/processing/extractor.py`

Questo componente si occupa dell'ingestion testuale e dell'Information Extraction. A differenza dei parser strutturati ad albero, il modulo implementa un'architettura Stream-Regex-Engine ottimizzata. Carica i file grezzi (.html, .txt o .csv) archiviati in sottocartelle della root data/sources/ leggendoli come flussi di stringhe lineari.

Attraverso i pattern compilati in src/memory/schema.py, esegue una scansione NER-like per estrarre sia le frequenze delle keyword che i vettori numerici legati alle unità di misura fisiche, garantendo l'immunità da formati HTML malformati spesso presenti.

5.2. Utils Layer: `src/utils/metrics.py`

Il modulo SemanticsEngine centralizza l'analisi statistica e quantifica il vuoto semantico. Utilizzando la libreria pandas, mappa le frequenze estratte per ogni file in un DataFrame strutturato. Calcola la matrice di correlazione di Pearson tramite l'algoritmo vettorizzato .corr(method='pearson') ed esporta i report descrittivi in formato CSV e JSON, generando infine l'asset grafico correlation_heatmap.png per la Dashboard Web tramite matplotlib.

5.3. Learning Layer: `src/learning/clusterer.py`

Il modulo `Intelligence-Clusterer` implementa la pipeline di Machine Learning non supervisionata. Il codice estrae il testo normalizzato da tutti i record salvati nelle sottocartelle della root data/extracted/. Utilizza TfidfVectorizer di scikit-learn impostando la rimozione delle stop-words inglesi per isolare il rumore linguistico, e addestra l'istanza KMeans(n_clusters=2, random_state=42). Il modulo genera infine un riepilogo in clustering_summary.json contenente le top-10 parole chiave più rilevanti per ogni cluster (calcolate tramite le coordinate dei centroidi cluster_centers_).

6. Interface Layer Web: L'Integrazione con Flask

Per ottemperare all'obiettivo di fornire molteplici punti di accesso al sistema intelligente, è stata sviluppata un'architettura di visualizzazione web dinamica che si affianca all'interfaccia a riga di comando (CLI).

6.1. Il file di inizializzazione dell'applicazione: `run\_web.py`

Il file `run_web.py` funge da entrypoint isolato per l'attivazione dell'interfaccia grafica del sistema. Esso si occupa di configurare l'ambiente di esecuzione, verificare la presenza dei moduli sorgente e istanziare il server HTTP di sviluppo nativo di Flask.

Il modulo web così strutturato realizza un'interfaccia reattiva ottimizzata:

- *Console di Log in Tempo Reale:* All'attivazione dei comandi dal front-end, l'interfaccia esegue chiamate `fetch()` asincrone verso `/api/run/pipeline`. Il ciclo visivo della progressbar e l'aggiornamento testuale dello stage riflettono lo stato del thread worker memorizzato in `PIPELINE_STATUS`.
- *Aggiornamento Reattivo:* Sfruttando un meccanismo di polling JavaScript impostato a intervalli regolari (500ms) verso l'endpoint `/api/status`, i contatori delle fonti caricate e dei file strutturati cambiano dinamicamente a schermo senza richiedere il ricaricamento distruttivo della pagina web (DOM manipulation mirata).
- *Mappatura dei Paradigmi:* L'interfaccia si configura come una Dashboard di Amministrazione di un Agente Intelligente. Essa non visualizza dati statici pre-calcolati, ma pilota attivamente l'attivazione e la sincronizzazione di ogni singolo componente dell'architettura distribuita.

```
import sys
import os

# Allineamento del path di sistema per risolvere i moduli del pacchetto 'src'
sys.path.append(os.path.abspath(os.path.dirname(__file__)))
from src.web.app import app
if __name__ == '__main__':
    # Attivazione del server Flask sulla porta standard 5000 con monitoraggio dei file (debug)
    print("[Interface Layer] Avvio del server web per la Dashboard TA...")
    app.run(host='127.0.0.1', port=5000, debug=True)
```

Questo script astrae l'avvio della componente grafica rispetto alla logica di business core, garantendo che l'utente possa scegliere in qualsiasi momento se operare tramite l'interfaccia CLI (`run_shell.py`) o tramite il browser web, senza alcuna mutua interferenza o dipendenza accoppiata (principio di Separation of Concerns).

6.2. Il modulo dell'applicazione Flask: `src/web/app.py`

Il modulo `app.py` rappresenta il controller centrale dell'Interface Layer. Esso espone le rotte web necessarie al caricamento dell'interfaccia e un set di API RESTful in formato JSON utili a monitorare lo stato di avanzamento delle elaborazioni e a servire gli asset statici (i grafici generati dai moduli analytics).

Al fine di non bloccare il loop degli eventi del server Flask durante le computazioni pesanti (come i download di rete o il clustering K-Means), il modulo lancia la pipeline di estrazione su un thread asincrono separato (`threading.Thread`), aggiornando uno stato globale monitorato dal front-end tramite polling continuo.

6.3. Pagina di riepilogo: `data/extracted/summary.html`

A completamento del modulo di visualizzazione, il sistema genera dinamicamente un artifact finale autonomo denominato `summary.html`, posizionato all'interno della directory di persistenza dei dati strutturati (`data/extracted/`).

Mentre la Dashboard Web principale funge da pannello di controllo reattivo e real-time dell'Agente Intelligente (guidando l'esecuzione asincrona delle tre fasi), la pagina `summary.html` si configura come un Report di Ispezione Statico e Autocontenuto. Esso viene compilato dal sub-modulo `verifier.py` o al termine della Fase 2 di Processing per offrire una panoramica tabellare immutabile di tutti i metadati estratti dall'intero corpus documentale, senza richiedere l'interrogazione continua delle API del backend.

Al fine di garantire la massima accessibilità e aderenza ai paradigmi di integrazione dei Sistemi Intelligenti per Internet, l'Interface Layer principale ospita, all'interno del widget "*Stato Reale dell'Infrastruttura Dati*", un link ipertestuale di reindirizzamento diretto (`href="/data/extracted/summary.html"`) configurato con l'attributo `target="_blank"`. Questa scelta architetturale consente al ricercatore di biforcare l'esperienza d'uso: da un lato mantiene attivo il monitoraggio dei processi sulla Dashboard, dall'altro apre in un pannello parallelo del browser l'ispezione analitica profonda dei file stoccati.

Il documento `summary.html` organizza i dati secondo uno schema tabellare rigido in cui ogni riga rappresenta un'entità scientifica estratta, evidenziando il nome del file sorgente, il sub-corpus di appartenenza (coerenza, transitori, frattale o sincronizzazione), i conteggi delle keyword del Thesaurus e i riferimenti numerici convertiti (MeV, V/m, μ s). Tale

risorsa rappresenta il punto di verifica fondamentale sia per il debug ingegneristico dell'accuratezza delle espressioni regolari, sia per la validazione manuale dei pattern fisici prima del loro passaggio ai motori di clustering statistico del Learning Layer.

7. Analisi delle Risultanze Sperimentali ed Evidenze della TA

L'esecuzione completa della pipeline automatica ha generato un dataset di ampiezza accademica, i cui log di computazione ed estratti numerici permettono di trarre conclusioni ingegneristiche e fisiche stabili.

File Elaborati Totali: 783
Valori Numerici Sospetti: 138625
Media / Mediana Campionaria: 207.43 / 30
Conteggi Globali Categorie Semantiche:
electric = 6912 occorrenze;
lightning = 2375 occorrenze;
nuclear = 9827 occorrenze;
temporal = 2501 occorrenze.


7.1. Analisi Quantitativa dell'Ingestion Layer

La pipeline esegue lo scaricamento controllato su 4 macro-campioni di Ingestion definiti in app.py: campionamento_1_coerenza_ta, campionamento_2_transitori_rc, campionamento_3_frattale_primi, campionamento_4_sincronizzazione_globale. Il sistema scarica con successo le risorse memorizzando i file grezzi in sotto-cartelle dedicate. Il processo di estrazione mappa l'intero corpus popolando le sottocartelle della root data/extracted/ con file JSON strutturati. Il file di monitoraggio globale summary.json memorizza le metriche strutturate di record potenziali estratti dai grandi archivi tabulari.

7.2. Interpretazione della Matrice di Correlazione Semantica

La matrice di Pearson calcolata dal 'Semantics-Engine' sul testo estratto dalle sezioni rileva i seguenti coefficienti:

Pearson	lightning	electric	nuclear	Temporal
lightning	1	0.3574313362231843	0.37060180747362176	0.38456638161177614
electric	0.3574313362231843	1	0.3210276459980252	0.27325878715061463
nuclear	0.37060180747362176	0.3210276459980252	1	0.32249873785826233
temporal	0.38456638161177614	0.27325878715061463	0.32249873785826233	1



Bremsstrahlung è una parola tedesca che significa letteralmente: "radiazione di frenamento"; si verifica quando una particella carica (tipicamente un elettrone) viene deviata o rallentata dal campo elettrico di un nucleo atomico. Durante il rallentamento: l'elettrone perde energia cinetica; parte di questa energia viene emessa sotto forma di fotoni; se l'energia è sufficientemente elevata, i fotoni prodotti sono raggi X o raggi gamma. Nei fenomeni atmosferici estremi: i campi elettrici dei temporali accelerano elettroni runaway; gli elettroni relativistici urtano l'atmosfera; viene prodotta Bremsstrahlung; si osservano i TGF (Terrestrial Gamma-ray Flashes).

Dall'analisi di questi coefficienti emergono tre considerazioni di rilievo:

1. L'Intersezione Nucleo-Atmosferica ('nuclear' VS 'lightning' = 0.37060180747362176): Attesta una correlazione positiva moderata all'interno della letteratura scientifica globale. I due domini non risultano statisticamente indipendenti; ciò convalida sperimentalmente come la produzione di radiazioni nucleari in atmosfera (TGF) non sia un fenomeno isolato, bensì intrinsecamente correlato alle dinamiche di scarica tipiche dei fulmini, supportando i presupposti fisici della Teoria dell'Avvicinamento.
2. La Firma del Transitorio Capacitivo ('nuclear' VS 'temporal' = 0.322498737858262333): Il legame matematico significativo tra le entità nucleari e le metriche temporali certifica che le reazioni ad alta energia avvengono in regimi transienti ultra-rapidi (su scale di microsecondi e nanosecondi). Tale evidenza avvalorava l'ipotesi della TA secondo cui i fenomeni nucleari atmosferici sono guidati dalla scarica impulsiva di un supercondensatore macroscopico regolato da costanti di tempo critiche RC.
3. Il Legame Elettrico-Temporale ('electric' VS 'temporal' = 0.27325878715061463): Mostra un valore parzialmente più contenuto. Questo andamento rispecchia lo stato dell'arte della fisica classica, in cui le grandezze elettriche macroscopiche vengono tradizionalmente modellate mediante equazioni differenziali continue su scale temporali estese, tralasciando la fine struttura microscopica e discontinua che emerge solo analizzando i transitori ad alta energia.

7.3. Risultanze del Machine Learning (Clustering)

L'algoritmo K-Means impostato a $k=2$ ha ripartito i documenti del corpus in due macro-comunità ad alta separabilità geometrica:

Cluster 0 (Fisica del Plasma e Dinamiche del Fulmine): Raggruppa i documenti incentrati su parametri macroscopici, correnti di scarica (A), campi elettrici (V/m), e modelli meteorologici tradizionali.

Cluster 1 (Eventi Nucleari e Alta Energia - TGF/TGE): Isola i paper specialistici focalizzati sulla fisica delle particelle energetiche, flussi di neutroni ($n/cm^2/s$), energie espresse in Mega-elettronvolt (MeV), ed i relativi modelli di Bremsstrahlung relativistica.

Conclusioni Epistemologiche: Il posizionamento fondamentale guidato dalle equazioni della Teoria dell'Avvicinamento [1] si colloca esattamente sul confine geometrico di transizione tra il Cluster 0 e il Cluster 1. Il sistema ha matematicamente dimostrato che la TA agisce da ponte analitico, unificando le due comunità scientifiche storicamente separate e colmando quel "vuoto semantico" tramite la chiave di lettura modellistica del super-condensatore atmosferico.

L'approccio ingegneristico impiegato, l'elevato volume di dati numerici estratti, e la stabilità dei moduli software realizzati, attestano il pieno soddisfacimento dei requisiti del progetto concluso nell'ambito dei Sistemi Intelligenti per Internet.

7.4. Semantic gap


I dati reali estratti dal file `semantic_gap_report.csv` mostrano quantitativamente l'ampiezza del vuoto semantico presente nella letteratura accademica tradizionale:

concept x	concept y	pearson r	pair semantic gap
electric	Lightning	0.3574	0.6426
electric	Nuclear	0.3706	0.6294
electric	Temporal	0.3846	0.6154
lightning	Nuclear	0.321	0.679
lightning	Temporal	0.2733	0.7267
nuclear	Temporal	0.3225	0.6775

L'indice di Semantic Gap, costantemente superiore alla soglia critica di 0.60 per tutte le coppie di parole chiave, dimostra analiticamente l'esistenza di una netta frammentazione epistemologica. Le comunità scientifiche della fisica dei fulmini e della fisica nucleare operano prevalentemente in "isole di conoscenza" separate.

Definizione generale: Esiste informazione su A ed esiste informazione su B, ma la letteratura o i dati disponibili mostrano poche connessioni esplicite tra A e B. Il vuoto semantico è quindi una proprietà della struttura della conoscenza, non dei singoli documenti. Supponiamo che il sistema abbia le categorie: electric; lightning; nuclear; temporal; e per ogni documento calcoli delle frequenze. Se due categorie mostrano una correlazione molto bassa: $r \approx 0$ significa che tendono a non comparire insieme. Questo può essere interpretato come: indipendenza semantica; separazione disciplinare; vuoto semantico. Se il K-Means separa nettamente i documenti in: Cluster A; Cluster B; allora il confine tra i cluster rappresenta una forma di vuoto semantico. Dal punto di vista dell'epistemologia della conoscenza, un vuoto semantico rappresenta: una regione della rete della conoscenza in cui i collegamenti tra concetti, discipline o comunità scientifiche risultano deboli, assenti o scarsamente documentati. Per questo

motivo i sistemi di Text Mining e Knowledge Discovery vengono spesso utilizzati per cercare: relazioni nascoste; connessioni interdisciplinari; aree emergenti della ricerca.




L'abbattimento di tale barriera si rileva esclusivamente nei cluster di documenti che adottano la prospettiva transitoria integrata (TA), dove le grandezze elettriche e i flussi nucleari vengono mappati sulle medesime scale temporali rapide.

7.5 Fase evolutiva

Il modulo di calcolo ha valutato il livello di consistenza semantica dei quattro stadi cardine previsti dalla ricerca in essere:

Fase Evolutiva / Profilo Letteratura	Profilo 1 (Prep. Elettrica)	Profilo 2 (Conv. Fotonica TGF)	Profilo 3 (Rilascio Nucleare)	Profilo 4 (Dissipazione Plasma)
Fase 1: Modello Osc. Smorzata	0.17	0.20	0.16	0.25
Fase 2: Modello RC Relativistico	0.22	0.26	0.27	0.61
Fase 3: Estensione Frattale	0.12	0.15	0.12	0.24
Fase 4: Sincronizzazione Transitori	0.14	0.15	0.15	0.23



I punteggi normalizzati evidenziano come la Fase 2 (Modello RC Relativistico) presenti la massima densità di riscontri testuali all'interno dei paper, toccando un picco di 0.61 in corrispondenza dei modelli di dissipazione plasmica. Questo dato indica che il nucleo matematico dei circuiti RC estremi operanti in regimi Runaway trova un solido riscontro nell'attuale modellistica teorica della letteratura, mentre le estensioni frattali e deterministiche (Fase 3 e Fase 4) rappresentano l'avanguardia speculativa meno presidiata, tracciando la rotta per le future pubblicazioni del dominio.

8. Conclusioni

Il sistema intelligente sviluppato ha dimostrato la piena fattibilità ingegneristica dell'applicazione di tecniche di Information Extraction, Text Mining e Machine Learning non supervisionato per l'analisi epistemologica della letteratura scientifica complessa. L'architettura software realizzata soddisfa rigorosamente i criteri di modularità, manutenibilità e reattività richiesti dai moderni paradigmi dei Sistemi Intelligenti per Internet.

Dal punto di vista informatico, l'integrazione di un motore di crawling adattivo multi-sorgente con un'interfaccia di elaborazione basata su espressioni regolari ottimizzate ha permesso di processare in modo fluido un corpus eterogeneo di documenti, normalizzando formati testuali differenti ed estraendo entità numerico-esplicithe strutturate in schemi standard JSON. La doppia interfaccia sviluppata – una CLI interattiva per l'amministrazione di sistema e una Dashboard Web reattiva basata su Flask con architettura asincrona a thread – garantisce un'eccellente usabilità e flessibilità operativa sia in scenari locali che di controllo remoto tramite API REST.

Dal punto di vista scientifico ed epistemologico, l'Analytics Layer e il Learning Layer hanno fornito una validazione matematica robusta ai postulati della Teoria dell'Avvicinamento (TA). Il calcolo delle correlazioni di Pearson e la successiva mappatura del Semantic Gap (stabilmente superiore a 0.60) hanno confermato analiticamente la presenza di un vuoto semantico storico tra la fisica nucleare ad alte energie e la fisica atmosferica tradizionale dei fulmini. Al contempo, l'algoritmo di clustering K-Means ha geometricamente isolato le due comunità come domini separati, dimostrando tuttavia come i modelli transitori e i meccanismi a circuito RC relativistico previsti dalla TA si posizionino esattamente sul confine di transizione geometrica tra i due cluster.

In conclusione, il sistema ha dimostrato che la Teoria dell'Avvicinamento non costituisce un modello isolato, ma si configura come l'anello di congiunzione analitico necessario a colmare il vuoto semantico della letteratura contemporanea. Lo strumento si attesta come una solida piattaforma di conoscenza automatizzata, pronta per essere estesa mediante l'integrazione di Large Language Models (LLM) locali per il raffinamento semantico delle relazioni estratte.

Il termine "elettroni relativistici (regime Runaway)" appartiene alla fisica dell'atmosfera e delle alte energie, il cui significato fisico è uguale a: un elettrone entra in regime Runaway ("in fuga") quando un campo elettrico molto intenso lo accelera più rapidamente di quanto i processi di collisione con l'aria riescano a rallentarlo. Normalmente un elettrone che attraversa l'atmosfera: collide con molecole di azoto e ossigeno; perde energia; viene rallentato. In condizioni estreme, come all'interno di forti campi elettrici temporaleschi, può verificarsi il contrario: il guadagno di energia dovuto al campo elettrico supera le perdite per collisione; l'elettrone continua ad accelerare; raggiunge energie relativistiche (velocità prossime a quella della luce). Questo fenomeno è noto come Runaway Electron Avalanche (RREA), una teoria sviluppata soprattutto da Alexander Gurevich per spiegare fenomeni atmosferici ad alta energia. Gli elettroni runaway possono: produrre raggi gamma ad alta energia tramite bremsstrahlung; contribuire alla formazione dei TGF (Terrestrial Gamma-ray Flashes); in particolari condizioni generare reazioni fotonucleari che producono neutroni.

Nella ricerca fatta è un concetto ancorante. Un sistema di text mining può quindi verificare: quanto frequentemente il concetto compaia; con quali altri concetti sia associato; se esista un "ponte" tra domini scientifici diversi.

Cos'è il Vocabulary Mismatch? Questo è un concetto centrale dell'Information Retrieval. Due autori possono descrivere lo stesso fenomeno usando parole diverse. Un motore ingenuo potrebbe considerarli fenomeni diversi. Creare un thesaurus: NUCLEAR = [neutron, gamma, radiation, flux, tgf] riduce il Vocabulary Mismatch.

9. Repository

https://github.com/DouglasRuffini/Sistemi_Intelligenti_Internet

10. Riferimenti

- [1] Ruffini, D. (2025), “Electron Approach Theory. A Damped Oscillation Model Based on Relativistic Effects and Space-Time Feedback.”, Press: The General Science Journal (ISSN 1916-5382), [published](#): 01/05/2025.
- [2] Ruffini, D. (2025), “Electron Approach Theory. Fractal Extension. Mathematical formalization of absolute space and absolute time as a recursive projection, by means of a weak conjecture of a weak conjecture deriving from Goldbach's strong conjecture.”, Press: The General Science Journal (ISSN 1916-5382), [published](#): 01/05/2025.
- [3] A. Chilingarian,* A. Daryan, K. Arakelyan, A. Hovhannisyan, B. Mailyan, L. Melkumyan, G. Hovsepyan, S. Chilingaryan, A. Reymers, and L. Vanyan.
Ground-based observations of thunderstorm-correlated fluxes of high-energy electrons, gamma rays, and neutrons
Artem Alikhanyan National Laboratory, Alikhanyan Brothers 2, Yerevan 36, Armenia
(Received 28 April 2010; [published](#) 23 August 2010)
- [4] G. N. Shah, H. Razdan, C. L. Bhat, and Q. M. Ali, [Nature](#) (London) 313, 773 (1985).
- [5] L. P. Babich and R. A. Roussel-Dupre, J. Geophys. Res. 112, [D13303](#) (2007).
- [6] L. P. Babich, L. I.Bochkov, I. M.Kutsyk, and R. A.Roussel-Dupre', J. Geophys. Res. 115, [A00E28](#) (2010).
- [7] Ruffini, D. (2025), The Mechanics of Time. – Book, Amazon - ISBN: 9798315083894 - [OSF](#)