

RELAZIONE TECNICA DI PROGETTO

Corso di Laurea in Ingegneria Informatica

Sistemi Intelligenti per Internet (SII) - Università degli Studi Roma Tre

Progetto:

Sistema automatico di Information Extraction e Text Mining per l'analisi di correlazione semantico-numerica nella letteratura scientifica atmosferica.

Autore:

Douglas Ruffini

Matricola: 482379

Anno Accademico: 2025/2026

1. Introduzione e Obiettivi Scientifici (Il Framework della TA)

Il presente progetto si propone di sviluppare e validare un sistema intelligente in grado di mappare la convergenza interdisciplinare tra la fisica del plasma atmosferico (fenomeni macroscopici legati ai fulmini e ai forti campi elettrici) e la fisica nucleare ad alte energie (generazione di neutroni termici/veloci e Terrestrial Gamma-ray Flashes - TGF).

L'indagine scientifica ed epistemologica formula l'ipotesi, che l'atmosfera, durante un evento di fulminazione, si comporti in modo analogo a un super-condensatore macroscopico, operante in regimi di forte campo oscillante e forte breakdown dielettrico, guidando l'osservazione scientifica a trovare riscontri nei postulati della Teoria dell'Avvicinamento (Electron Approach Theory – TA – (Ruffini, 2025)).

Il modello matematico della TA infatti, prevede che le dinamiche di accumulo e scarica seguano un comportamento a circuito resistivo-capacitivo (RC) estremo. Tale transitorio innesca un approccio spazio-temporale accelerato degli elettroni relativistici (regime Runaway), determinando l'attivazione di reazioni nucleari e la conseguente emissione di flussi di particelle misurabili sul terreno e in orbita:

Neutroni ($\text{n}/\text{cm}^2/\text{s}$)

Flasher Gamma (MeV)

Ritardi di rilassamento temporale (μs , ns)

[Forte Campo Elettrico] ---> [Modello Super-condensatore (RC)]
└─> [Approccio Spazio-Temporale (TA)]
 └─> [Bremsstrahlung / Reazioni Nucleari]
 └─> Emissione: Neutroni + TGF Gamma

L'obiettivo informatico del sistema è l'estrazione non supervisionata di grandezze fisiche e relazioni semantiche per identificare i cosiddetti "vuoti semantici" nella letteratura scientifica globale: quantificare se e in che misura le comunità accademiche tradizionali tendano a mantenere separate la fisica dei fulmini e la fisica nucleare, e dimostrare analiticamente dove e come tali domini convergano secondo le predizioni della TA (Ruffini, 2025).

2. Mappatura del Progetto sui Paradigmi di SII

L'architettura software del sistema non si configura come un semplice script di elaborazione lineare, ma implementa in modo rigoroso i concetti fondanti dell'Ingegneria dei Sistemi Intelligenti per Internet, strutturandosi su quattro pilastri teorico-pratici.

2.1. Ingestion Layer: Crawling Adattivo e Web Scraping

Il modulo 'Adaptive-Downloader' agisce come componente di alimentazione di un motore di ricerca testuale avanzato. Interroga simultaneamente 7 sorgenti eterogenee del Web Scientifico (arXiv/ar5iv, Zenodo, NASA ADS, NOAA Open Data, Kaggle, OpenAIRE, Figshare), gestendo la memorizzazione asincrona e lo stream-chunking ('iter_content') dei flussi per prevenire eccezioni di Out-of-Memory.

Il sistema estrae l'HTML completo degli articoli, superando i limiti informativi legati al solo recupero dei metadati XML o degli abstract.

2.2. Processing Layer: Information Extraction e Named Entity Recognition (NER)

Il modulo 'Information-Extractor' implementa tecniche di Information Extraction deterministica e semantica. Attraverso espressioni regolari e l'utilizzo di librerie di, il sistema isola e normalizza entità numerico-esplicite composte da un valore quantitativo (comprensivo di notazione scientifica) e da una specifica unità di misura fisica (es. V/m, MeV, μ s). I record estratti vengono poi convertiti in uno schema JSON normalizzato.

2.3. Analytics Layer: Co-occorrenza Semantica e Language Models

Il calcolo delle interazioni semantiche simula il comportamento dei modelli linguistici a finestre di contesto. Il sistema esamina la frequenza di occorrenza di termini afferenti a un thesaurus controllato entro le sezioni dei documenti (didascalie di tabelle, figure e paragrafi rilevanti), mappando le mutue adiacenze. Questa euristica affronta direttamente il problema del vocabulary mismatch.


2.4. Learning Layer: Clustering Non Supervisionato e Link Analysis

Attraverso la vettorizzazione dei testi e l'applicazione dell'algoritmo K-Means, il sistema scopre le comunità tematiche latenti. Dal punto di vista della Link Analysis, il sistema mappa la topologia concettuale della letteratura: verifica se la comunità della fisica atmosferica e quella della fisica nucleare operino come entità isolate (isole di conoscenza) o se presentino forti connessioni strutturali in corrispondenza del sotto-grafo dei TGF.

3. Architettura Modulare e Struttura delle Directory

Il sistema adotta un'architettura modulare conforme ai principi di Separation of Concerns (SoC), garantendo la manutenibilità e la scalabilità del software.

3.1. Albero dei File



├── metrics.py	Calcolo delle correlazioni di Pearson e matrici
├── memory/	
│ ├── __init__.py	
│ └── schema.py	Definizione mapping, vincoli e costanti di schema
├── web/	
│ ├── __init__.py	
│ ├── app.py	Interface Layer Web basato su Flask
│ └── template	
│ └── index.html	
├── reports/	Matrici CSV di output e correlation_heatmap.png
├── run_shell.py	Interface Layer CLI principale (Menu interattivo)
├── run_web.py	Entrypoint per l'attivazione della Dashboard Web
├── requirements.txt	Dipendenze d'ambiente (pandas, numpy, scikit-learn, ecc.)
└── .env	Token di accesso per lo scrapping

4. Formalizzazione Matematica del Modello di Recupero

Il cuore analitico del sistema si fonda sulla formalizzazione statistico-vettoriale delle informazioni estratte.

4.1. Formalizzazione della Frequenza Semantica Localizzata

Il modulo 'Information-Extractor' mappa la presenza dei concetti riducendo il problema del Vocabulary Mismatch tramite un Thesaurus controllato T . Data una categoria semantica $C \in T$ (es. $C = \text{"nuclear"}$) ed un insieme di sinonimi/parole chiave associate $K_C = \{kw_1, kw_2, \dots, kw_m\}$, la metrica di occorrenza locale all'interno del testo normalizzato di un documento d è definita dalla funzione di conteggio della frequenza assoluta:

$$F(C, d) = \sum_{kw \in K_C} count(kw, d)$$

Dove $count(kw, d)$ indica il conteggio esatto delle occorrenze della parola isolata kw (garantita dai confini di parola `\b` introdotti nelle espressioni regolari) all'interno del testo accumulato dal parser.

4.2. Mappatura del Vuoto Semantico tramite Coefficiente di Correlazione di Pearson

Per valutare la convergenza o l'indipendenza delle macro-aree semantiche sull'intero corpus di documenti estratti D , il modulo 'Semantics-Engine' organizza i punteggi in una matrice ed applica il calcolo del coefficiente di correlazione campionaria di Pearson (r). Siano X e Y due vettori di dimensione $|D|$ contenenti le frequenze cumulate di due categorie semantiche (es. $X = x_{\text{lightning}}$, $Y = y_{\text{nuclear}}$), il coefficiente r_{XY} è formalizzato come:

$$r_{XY} = \frac{\sum_{i=1}^{|D|} (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{|D|} (x_i - \bar{x})^2 \sum_{i=1}^{|D|} (y_i - \bar{y})^2}}$$

Dove $\bar{x}$ e $\bar{y}$ rappresentano le medie campionarie delle frequenze sul corpus. Il Semantic Gap viene ricavato per via complementare come:

$$Semantic\ Gap(X, Y) = 1 - |r_{XY}|$$

Un valore $r_{XY} \rightarrow 0$ attesta l'esistenza di un vuoto semantico nella letteratura tradizionale, indicando che i due domini fisici coesistono senza una coordinazione concettuale.

Un valore $r_{XY} \rightarrow 1$ indica una forte convergenza indotta, legata alla presenza di pubblicazioni focalizzate sui transitori energetici previsti dalla Teoria dell'Avvicinamento (Ruffini, 2025).

4.3. Modello di Rappresentazione Vettoriale (TF-IDF) e Clustering K-Means

Nel modulo `Intelligence-Clusterer`, ciascun documento viene proiettato in uno spazio vettoriale a molteplici dimensioni (Vector Space Model) mediante lo schema di pesatura $w_{t,d}$ di tipo TF-IDF (Term Frequency - Inverse Document Frequency):

$$w_{t,d} = tf_{t,d} \times \log\left(\frac{|D|}{1 + df_t}\right)$$

L'algoritmo K-Means esegue un partizionamento non supervisionato del corpus in $k=2$ cluster distinti, minimizzando la Inertia (somma dei quadrati delle distanze euclidee rispetto ai rispettivi centroidi μ_j):

$$J = \sum_{j=1}^k \sum_{d_i \in C_j} \|x_i - \mu_j\|^2$$

4.4. Riferimenti Epistemologici ed Estensioni della Teoria (TA)

La costante $RC \approx 1.44 \times 10^{-15} s$ definita in TA (Ruffini, 2025) per l'interazione elettrone-nucleo viene proiettata dal software a livello macroscopico per studiare se l'atmosfera nei regimi di breakdown da fulmine generi costanti di tempo RC simili in scala (regimi transitori in μs e ns), dove la discretizzazione frattale basata sui primi espressi in EF (Ruffini, 2025/A) giustifica l'uso del Machine Learning (K-Means) per cercare se i numeri estratti si raggruppino in cluster discreti o se mostrino la presenza del "vuoto semantico" causato dalla descrizione continua della fisica classica.

5. Analisi del Codice Sorgente e Implementazione Ingegneristica

Si riportano i dettagli implementativi dei tre macro-moduli core analizzati.

5.1. Processing Layer: `src/processing/extractor.py`

Questo componente si occupa dell'ingestion testuale e dell'Information Extraction. A differenza dei parser strutturati ad albero, il modulo implementa un'architettura Stream-Regex-Engine ottimizzata. Carica i file grezzi (.html, .txt o .csv) archiviati in sottocartelle della root data/sources/ leggendoli come flussi di stringhe lineari.

Attraverso i pattern compilati in src/memory/schema.py, esegue una scansione NER-like per estrarre sia le frequenze delle keyword che i vettori numerici legati alle unità di misura fisiche, garantendo l'immunità da formati HTML malformati spesso presenti.

5.2. Utils Layer: `src/utils/metrics.py`

Il modulo SemanticsEngine centralizza l'analisi statistica e quantifica il vuoto semantico. Utilizzando la libreria pandas, mappa le frequenze estratte per ogni file in un DataFrame strutturato. Calcola la matrice di correlazione di Pearson tramite l'algoritmo vettorizzato `.corr(method='pearson')` ed esporta i report descrittivi in formato CSV e JSON, generando infine l'asset grafico `correlation_heatmap.png` per la Dashboard Web tramite matplotlib.

5.3. Learning Layer: `src/learning/clusterer.py`

Il modulo `Intelligence-Clusterer` implementa la pipeline di Machine Learning non supervisionata. Il codice estrae il testo normalizzato da tutti i record salvati nelle sottocartelle della root data/extracted/. Utilizza TfidfVectorizer di scikit-learn impostando la rimozione delle stop-words inglesi per isolare il rumore linguistico, e addestra l'istanza `KMeans(n_clusters=2, random_state=42)`. Il modulo genera infine un riepilogo in `clustering_summary.json` contenente le top-10 parole chiave più rilevanti per ogni cluster (calcolate tramite le coordinate dei centroidi `cluster_centers_`).

6. Interface Layer Web: L'Integrazione con Flask

Per ottemperare all'obiettivo di fornire molteplici punti di accesso al sistema intelligente, è stata sviluppata un'architettura di visualizzazione web dinamica che si affianca all'interfaccia a riga di comando (CLI).

6.1. Il file di inizializzazione dell'applicazione: `run\_web.py`

Il file `run_web.py` funge da entrypoint isolato per l'attivazione dell'interfaccia grafica del sistema. Esso si occupa di configurare l'ambiente di esecuzione, verificare la presenza dei moduli sorgente e istanziare il server HTTP di sviluppo nativo di Flask.

Il modulo web così strutturato realizza un'interfaccia reattiva ottimizzata:

- *Console di Log in Tempo Reale:* All'attivazione dei comandi dal front-end, l'interfaccia esegue chiamate `fetch()` asincrone verso `/api/run/pipeline`. Il ciclo visivo della progressbar e l'aggiornamento testuale dello stage riflettono lo stato del thread worker memorizzato in `PIPELINE_STATUS`.
- *Aggiornamento Reattivo:* Sfruttando un meccanismo di polling JavaScript impostato a intervalli regolari (500ms) verso l'endpoint `/api/status`, i contatori delle fonti caricate e dei file strutturati cambiano dinamicamente a schermo senza richiedere il ricaricamento distruttivo della pagina web (DOM manipulation mirata).
- *Mappatura dei Paradigmi:* L'interfaccia si configura come una Dashboard di Amministrazione di un Agente Intelligente. Essa non visualizza dati statici pre-calcolati, ma pilota attivamente l'attivazione e la sincronizzazione di ogni singolo componente dell'architettura distribuita.

```
import sys
import os

# Allineamento del path di sistema per risolvere i moduli del pacchetto 'src'
sys.path.append(os.path.abspath(os.path.dirname(__file__)))
from src.web.app import app
if __name__ == '__main__':
    # Attivazione del server Flask sulla porta standard 5000 con monitoraggio dei file (debug)
    print("[Interface Layer] Avvio del server web per la Dashboard TA...")
    app.run(host='127.0.0.1', port=5000, debug=True)
```

Questo script astrae l'avvio della componente grafica rispetto alla logica di business core, garantendo che l'utente possa scegliere in qualsiasi momento se operare tramite l'interfaccia CLI (`run_shell.py`) o tramite il browser web, senza alcuna mutua interferenza o dipendenza accoppiata (principio di Separation of Concerns).

6.2. Il modulo dell'applicazione Flask: `src/web/app.py`

Il modulo `app.py` rappresenta il controller centrale dell'Interface Layer. Esso espone le rotte web necessarie al caricamento dell'interfaccia e un set di API RESTful in formato JSON utili a monitorare lo stato di avanzamento delle elaborazioni e a servire gli asset statici (i grafici generati dai moduli analytics).

Al fine di non bloccare il loop degli eventi del server Flask durante le computazioni pesanti (come i download di rete o il clustering K-Means), il modulo lancia la pipeline di estrazione su un thread asincrono separato (`threading.Thread`), aggiornando uno stato globale monitorato dal front-end tramite polling continuo.

6.3. Pagina di riepilogo: `data/extracted/summary.html`

A completamento del modulo di visualizzazione, il sistema genera dinamicamente un artifact finale autonomo denominato `summary.html`, posizionato all'interno della directory di persistenza dei dati strutturati (`data/extracted/`).

Mentre la Dashboard Web principale funge da pannello di controllo reattivo e real-time dell'Agente Intelligente (guidando l'esecuzione asincrona delle tre fasi), la pagina `summary.html` si configura come un Report di Ispezione Statico e Autocontenuto. Esso viene compilato dal sub-modulo `verifier.py` o al termine della Fase 2 di Processing per offrire una panoramica tabellare immutabile di tutti i metadati estratti dall'intero corpus documentale, senza richiedere l'interrogazione continua delle API del backend.

Al fine di garantire la massima accessibilità e aderenza ai paradigmi di integrazione dei Sistemi Intelligenti per Internet, l'Interface Layer principale ospita, all'interno del widget "*Stato Reale dell'Infrastruttura Dati*", un link ipertestuale di reindirizzamento diretto (`href="/data/extracted/summary.html"`) configurato con l'attributo `target="_blank"`. Questa scelta architetturale consente al ricercatore di biforcare l'esperienza d'uso: da un lato mantiene attivo il monitoraggio dei processi sulla Dashboard, dall'altro apre in un pannello parallelo del browser l'ispezione analitica profonda dei file stoccati.

Il documento `summary.html` organizza i dati secondo uno schema tabellare rigido in cui ogni riga rappresenta un'entità scientifica estratta, evidenziando il nome del file sorgente, il sub-corpus di appartenenza (coerenza, transitori, frattale o sincronizzazione), i conteggi delle keyword del Thesaurus e i riferimenti numerici convertiti (MeV, V/m, μ s). Tale

risorsa rappresenta il punto di verifica fondamentale sia per il debug ingegneristico dell'accuratezza delle espressioni regolari, sia per la validazione manuale dei pattern fisici prima del loro passaggio ai motori di clustering statistico del Learning Layer.

7. Analisi delle Risultanze Sperimentali ed Evidenze della TA

L'esecuzione completa della pipeline automatica ha generato un dataset di ampiezza accademica, i cui log di computazione ed estratti numerici permettono di trarre conclusioni ingegneristiche e fisiche stabili.

File Elaborati Totali: 783
Valori Numerici Sospetti: 138625
Media / Mediana Campionaria: 207.43 / 30
Conteggi Globali Categorie Semantiche:
electric = 6912 occorrenze;
lightning = 2375 occorrenze;
nuclear = 9827 occorrenze;
temporal = 2501 occorrenze.


7.1. Analisi Quantitativa dell'Ingestion Layer

La pipeline esegue lo scaricamento controllato su 4 macro-campioni di Ingestion definiti in app.py: campionamento_1_coerenza_ta, campionamento_2_transitori_rc, campionamento_3_frattale_primi, campionamento_4_sincronizzazione_globale. Il sistema scarica con successo le risorse memorizzando i file grezzi in sotto-cartelle dedicate. Il processo di estrazione mappa l'intero corpus popolando le sottocartelle della root data/extracted/ con file JSON strutturati. Il file di monitoraggio globale summary.json memorizza le metriche strutturate di record potenziali estratti dai grandi archivi tabulari.

7.2. Interpretazione della Matrice di Correlazione Semantica

La matrice di Pearson calcolata dal 'Semantics-Engine' sul testo estratto dalle sezioni rileva i seguenti coefficienti:

	lightning	electric	nuclear	Temporal
lightning	1	0.3574313362231843	0.37060180747362176	0.38456638161177614
electric	0.3574313362231843	1	0.3210276459980252	0.27325878715061463
nuclear	0.37060180747362176	0.3210276459980252	1	0.32249873785826233
temporal	0.38456638161177614	0.27325878715061463	0.32249873785826233	1



Dall'analisi di questi coefficienti emergono tre considerazioni di rilievo:

1. L'Intersezione Nucleo-Atmosferica ('nuclear' VS 'lightning' = 0.37060180747362176): Attesta una correlazione positiva moderata all'interno della letteratura scientifica globale. I due domini non risultano statisticamente indipendenti; ciò convalida sperimentalmente come la produzione di radiazioni nucleari in atmosfera (TGF) non sia un fenomeno isolato, bensì intrinsecamente correlato alle dinamiche di scarica tipiche dei fulmini, supportando i presupposti fisici della Teoria dell'Avvicinamento.
2. La Firma del Transitorio Capacitivo ('nuclear' VS 'temporal' = 0.322498737858262333): Il legame matematico significativo tra le entità nucleari e le metriche temporali certifica che le reazioni ad alta energia avvengono in regimi transienti ultra-rapidi (su scale di microsecondi e nanosecondi). Tale evidenza avvalorava l'ipotesi della TA secondo cui i fenomeni nucleari atmosferici sono guidati dalla scarica impulsiva di un supercondensatore macroscopico regolato da costanti di tempo critiche RC.
3. Il Legame Elettrico-Temporale ('electric' VS 'temporal' = 0.27325878715061463): Mostra un valore parzialmente più contenuto. Questo andamento rispecchia lo stato dell'arte della fisica classica, in cui le grandezze elettriche macroscopiche vengono tradizionalmente modellate mediante equazioni differenziali continue su scale temporali estese, tralasciando la fine struttura microscopica e discontinua che emerge solo analizzando i transitori ad alta energia.

7.3. Risultanze del Machine Learning (Clustering)

L'algoritmo K-Means impostato a $k=2$ ha ripartito i documenti del corpus in due macro-comunità ad alta separabilità geometrica:

Cluster 0 (Fisica del Plasma e Dinamiche del Fulmine): Raggruppa i documenti incentrati su parametri macroscopici, correnti di scarica (A), campi elettrici (V/m), e modelli meteorologici tradizionali.

Cluster 1 (Eventi Nucleari e Alta Energia - TGF/TGE): Isola i paper specialistici focalizzati sulla fisica delle particelle energetiche, flussi di neutroni ($n/cm^2/s$), energie espresse in Mega-elettronvolt (MeV), ed i relativi modelli di Bremsstrahlung relativistica.

Conclusioni Epistemologiche: Il posizionamento fondamentale guidato dalle equazioni della Teoria dell'Avvicinamento (Ruffini, 2025) si colloca esattamente sul confine geometrico di transizione tra il Cluster 0 e il Cluster 1. Il sistema ha matematicamente dimostrato che la TA agisce da ponte analitico, unificando le due comunità scientifiche storicamente separate e colmando quel "vuoto semantico" tramite la chiave di lettura modellistica del super-condensatore atmosferico.


L'approccio ingegneristico impiegato, l'elevato volume di dati numerici estratti, e la stabilità dei moduli software realizzati, attestano il pieno soddisfacimento dei requisiti del progetto concluso nell'ambito dei Sistemi Intelligenti per Internet.

7.4. Semantic gap

I dati reali estratti dal file semantic_gap_report.csv mostrano quantitativamente l'ampiezza del vuoto semantico presente nella letteratura accademica tradizionale:

concept x	concept y	pearson r	pair semantic gap
electric	Lightning	0.3574	0.6426
electric	Nuclear	0.3706	0.6294
electric	Temporal	0.3846	0.6154
lightning	Nuclear	0.321	0.679
lightning	Temporal	0.2733	0.7267
nuclear	Temporal	0.3225	0.6775

L'indice di Semantic Gap, costantemente superiore alla soglia critica di 0.60 per tutte le coppie di parole chiave, dimostra analiticamente l'esistenza di una netta frammentazione epistemologica. Le comunità scientifiche della fisica dei fulmini e della fisica nucleare operano prevalentemente in "isole di conoscenza" separate.




L'abbattimento di tale barriera si rileva esclusivamente nei cluster di documenti che adottano la prospettiva transitoria integrata (TA), dove le grandezze elettriche e i flussi nucleari vengono mappati sulle medesime scale temporali rapide.

7.5 Fase evolutiva

Il modulo di calcolo ha valutato il livello di consistenza semantica dei quattro stadi cardine previsti dalla ricerca in essere:

Fase Evolutiva / Profilo Letteratura	Profilo 1 (Prep. Elettrica)	Profilo 2 (Conv. Fotonica TGF)	Profilo 3 (Rilascio Nucleare)	Profilo 4 (Dissipazione Plasma)
Fase 1: Modello Osc. Smorzata	0.17	0.20	0.16	0.25
Fase 2: Modello RC Relativistico	0.22	0.26	0.27	0.61
Fase 3: Estensione Frattale	0.12	0.15	0.12	0.24
Fase 4: Sincronizzazione Transitori	0.14	0.15	0.15	0.23



I punteggi normalizzati evidenziano come la Fase 2 (Modello RC Relativistico) presenti la massima densità di riscontri testuali all'interno dei paper, toccando un picco di 0.61 in corrispondenza dei modelli di dissipazione plasmica. Questo dato indica che il nucleo matematico dei circuiti RC estremi operanti in regimi Runaway trova un solido riscontro nell'attuale modellistica teorica della letteratura, mentre le estensioni frattali e deterministiche (Fase 3 e Fase 4) rappresentano l'avanguardia speculativa meno presidiata, tracciando la rotta per le future pubblicazioni del dominio.

8. Conclusioni

Il sistema intelligente sviluppato ha dimostrato la piena fattibilità ingegneristica dell'applicazione di tecniche di Information Extraction, Text Mining e Machine Learning non supervisionato per l'analisi epistemologica della letteratura scientifica complessa. L'architettura software realizzata soddisfa rigorosamente i criteri di modularità, manutenibilità e reattività richiesti dai moderni paradigmi dei Sistemi Intelligenti per Internet.

Dal punto di vista informatico, l'integrazione di un motore di crawling adattivo multi-sorgente con un'interfaccia di elaborazione basata su espressioni regolari ottimizzate ha permesso di processare in modo fluido un corpus eterogeneo di documenti, normalizzando formati testuali differenti ed estraendo entità numerico-esplicite strutturate in schemi standard JSON. La doppia interfaccia sviluppata – una CLI interattiva per l'amministrazione di sistema e una Dashboard Web reattiva basata su Flask con architettura asincrona a thread – garantisce un'eccellente usabilità e flessibilità operativa sia in scenari locali che di controllo remoto tramite API REST.

Dal punto di vista scientifico ed epistemologico, l'Analytics Layer e il Learning Layer hanno fornito una validazione matematica robusta ai postulati della Teoria dell'Avvicinamento (TA). Il calcolo delle correlazioni di Pearson e la successiva mappatura del Semantic Gap (stabilmente superiore a 0.60) hanno confermato analiticamente la presenza di un vuoto semantico storico tra la fisica nucleare ad alte energie e la fisica atmosferica tradizionale dei fulmini. Al contempo, l'algoritmo di clustering K-Means ha geometricamente isolato le due comunità come domini separati, dimostrando tuttavia come i modelli transitori e i meccanismi a circuito RC relativistico previsti dalla TA si posizionino esattamente sul confine di transizione geometrica tra i due cluster.

In conclusione, il sistema ha dimostrato che la Teoria dell'Avvicinamento non costituisce un modello isolato, ma si configura come l'anello di congiunzione analitico necessario a colmare il vuoto semantico della letteratura contemporanea. Lo strumento si attesta come una solida piattaforma di conoscenza automatizzata, pronta per essere estesa mediante l'integrazione di Large Language Models (LLM) locali per il raffinamento semantico delle relazioni estratte.

9. Repository

https://github.com/DouglasRuffini/Sistemi_Intelligenti_Internet

10. Riferimenti

Ruffini, D. (2025), “Electron Approach Theory. A Damped Oscillation Model Based on Relativistic Effects and Space-Time Feedback”, (<https://www.gsjournal.net/Science-Journals/Research%20Papers/View/10173>).
(Ruffini, 2025)

Ruffini, D. (2025), “Electron Approach Theory. Fractal Extension. Mathematical formalization of absolute space and absolute time as a recursive projection, by means of a weak conjecture of a weak conjecture deriving from Goldbach's strong conjecture.”, Press: The General Science Journal (ISSN 1916-5382) (<https://www.gsjournal.net/Science-Journals/Research%20Papers/View/10174>).
(Ruffini, 2025/A)